PRÁCTICA INTEGRADORA FINAL · 2026

Práctica Integradora Final 2026

Informe técnico consolidado

Aplicación Conduit/RealWorld contenerizada con PostgreSQL 16, réplica streaming, CI/CD, monitoreo, automatización con n8n y gestión de incidencias con Mantis.

Rol	Responsabilidad	Secciones
R1	Infraestructura y base de datos	§4, §5, §6
R2	Aplicación y CI/CD	§1, §3, §7, §8
R3	Observabilidad e incidencias	§10, §11
R4	Automatización	§12, §13
R5	Seguridad y documentación	§9, §14, §15

Repositorio: https://github.com/TomasGudi/HIA-2026
Backlog: Jira HIA-Scrum-2026 · Tablero HS2
Fecha: 17 de noviembre de 2026

Índice

01 — Descripción de la aplicación

1. Qué es
2. Usuarios y permisos
3. Funcionalidades
4. Alcance del integrador
5. Diagnóstico técnico inicial y plan de mejoras
6. Evidencia

02 — Arquitectura general

1. Vista de despliegue
2. Componentes y responsabilidades
3. Redes y exposición
4. Flujo de una petición
5. Replicación
6. CI/CD
7. Monitoreo y alertas
8. Publicación en Internet
9. Decisiones estructurales
10. Estado actual

03 — Inventario tecnológico

Backend

Frontend (reescrito, D-18)

Base de datos

Infraestructura

Servicios previstos (§10, §11, §12, §13)

Eventos de ciberseguridad considerados al elegir el stack

Evidencia

04 — Manual de instalación

1. Objetivo
2. Requisitos
3. Instalación paso a paso
4. Verificación
5. Puertos publicados
6. Problemas frecuentes
7. Tiempos medidos
8. Decisiones
9. Limitaciones
10. Preguntas frecuentes

05 — Configuración Docker

1. Servicios
2. Redes
3. Volúmenes
4. Imágenes
5. Variables de entorno
6. Verificación (evidencia)
7. Limitaciones

06 — Migración y carga de datos

1. Objetivo
2. Método
3. Tiempos medidos
4. Tamaño final
5. Incidente de carga y su resolución (D-19)
6. Verificación de integridad (evidencia)
7. Parámetros ajustados para la carga (D-20)
8. Reproducción
9. Limitaciones

07 — Informe de optimización SQL

1. Método
2. Resultado general
3. Análisis consulta por consulta
4. Índices y objetos creados: justificación y costo
5. Parámetros del motor
6. Limitaciones
7. Evidencia

08 — Configuración y pruebas de replicación

1. Arquitectura implementada
2. Configuración
3. Verificación de replicación
4. Pruebas de fallo
5. Failover: procedimiento manual (no automático)
6. Divergencia detectada (lo más importante de la prueba)
7. Limitaciones
8. Evidencia

09 — Integración y despliegue continuos

1. Objetivo
2. Herramienta
3. Integración continua (.github/workflows/ci.yml)
4. Protección de main
5. Publicación de imágenes (.github/workflows/release.yml)
6. Registro
7. Despliegue pull-based (scripts/deploy.ps1)
8. Rollback probado
9. Flujo completo
10. Estado
11. Evidencia

10 — Publicación en Internet

1. Objetivo
2. Arquitectura de publicación
3. Endpoints publicados
4. Autenticación en rutas administrativas
5. Verificación de superficie con nmap
6. Riesgos y limitaciones
7. Plan B: Tailscale Funnel

8. Evidencia

11 — Monitoreo

1. Objetivo y alcance
2. Arquitectura
3. Targets y qué mide cada uno
4. Las 6 reglas y su umbral
5. Dashboard (monitoring/dashboards/pi-overview.json)
6. Limitaciones encontradas (y qué se hizo)
7. Fuera de alcance
8. Operación
9. Evidencia

12 — Gestión de incidencias (Mantis)

1. Objetivo
2. Herramienta y despliegue
3. Incidentes del despliegue (reales, encontrados durante la puesta en marcha)
4. Configuración de categorías y prioridades
5. Vinculación con el código
6. Estado
7. Configuración
8. Las incidencias registradas

11, #14).

9. Proceso de gestión
10. Campos personalizados
11. Evidencia

13 — Automatización con n8n

1. Objetivo
2. Despliegue
3. Flujo 1 — Alerta de Prometheus a incidencia en Mantis
4. Pruebas de integración
5. Riesgos de las automatizaciones
6. Flujo 2 — Verificación de backup
7. Flujo 3 — Informe semanal a Nextcloud
8. Flujo 4 — no implementado
9. Evidencia

14 — Seguridad informática

1. Objetivo y alcance
2. Matriz STRIDE
3. Informe de vulnerabilidades
4. Controles aplicados
5. Pruebas controladas
6. Runbook de respuesta a incidentes
7. Limitaciones declaradas
8. Flujo de incidentes con n8n
9. Evidencia

15 — Backup y restauración

1. Política
2. Ejecución y resultados medidos

3. Prueba de restauración
4. Persistencia de datos (volúmenes)
5. Limitaciones
6. Evidencia

16 — Limitaciones y mejoras futuras

1. Objetivo
2. Limitaciones de arquitectura
3. Limitaciones de datos
4. Limitaciones de seguridad
5. Limitaciones de automatización
6. Limitaciones de gestión
7. Limitaciones de publicación
8. Lo que sí está resuelto
9. Mejoras priorizadas
10. Preguntas frecuentes

01 — Descripción de la aplicación

1. Qué es

Conduit es una aplicación web de publicación de artículos (blog social tipo Medium) que implementa el contrato de API **RealWorld**: usuarios, artículos, etiquetas, comentarios, favoritos y seguimiento entre usuarios. Es el caso de estudio que la comunidad RealWorld usa para comparar implementaciones de stacks completos.

El proyecto del integrador **reutiliza el backend** de referencia (`node-express-realworld-example-app`, MIT) y **reescribe la capa de presentación** con Vite + React 18 (ver `docs/05-decisiones.md` D-18). El dominio, el esquema relacional y el contrato de API son los de la aplicación existente.

2. Usuarios y permisos

Rol	Puede	No puede
Visitante (sin sesión)	Ver listado de artículos, filtrar por etiqueta, leer un artículo y sus comentarios	Publicar, comentar, favoritear
Usuario registrado	Todo lo anterior + publicar artículos, comentar, marcar favoritos, editar su perfil	Editar o borrar artículos de otros
Administrador de infraestructura	Acceder a pgAdmin, Grafana, n8n y Mantis **por túnel**	Acceder desde Internet sin autenticación

3. Funcionalidades

#	Funcionalidad	Origen	Estado
F1	Registro e inicio de sesión con JWT	heredada (backend)	operativa
F2	Listado paginado de artículos	heredada	operativa
F3	Filtro por etiqueta	heredada	operativa
F4	Detalle de artículo con comentarios	heredada	operativa
F5	Publicación de artículos con etiquetas	heredada	operativa
F6	Comentarios sobre artículos	heredada	operativa
F7	Favoritos por usuario	heredada (API)	API operativa; botón en UI: pendiente
F8	Perfil de usuario y seguimiento	heredada (API)	API operativa; pantalla: pendiente
F9	Feed de autores seguidos	heredada (API)	API operativa; pantalla: pendiente
F10	Interfaz SPA con rutas y proxy `/api`	**reescrita**	operativa
F11	Endpoint `/healthz` para monitoreo	**agregada**	operativa
F12	Dataset sintético de 6M por tabla de volumen	**agregada**	operativa

Las funcionalidades F7–F9 existen en la API y son parte del contrato, pero la interfaz de demostración prioriza los flujos que se muestran en la defensa. Se declaran como alcance parcial en `docs/informe/16-limitaciones.md` en lugar de figurar como terminadas.

4. Alcance del integrador

Se modifica	Se agrega
Conexión a PostgreSQL por variables de entorno	Contenerización completa (DB, backend, frontend)
Validación obligatoria de `JWT_SECRET`	Réplica streaming + failover manual

Se modifica	Se agrega
Capa de presentación (reescrita)	Dataset masivo + 8 consultas optimizadas
—	CI/CD, monitoreo, backups, incidencias, n8n, seguridad

5. Diagnóstico técnico inicial y plan de mejoras

Hallazgos sobre el estado recibido (antes de intervenir), con su tratamiento.

#	Hallazgo	Categoría	Impacto	Mejora aplicada	Sección
H1	`JWT_SECRET` con fallback `'superSecret'`: si la variable falta, la API firma tokens con una clave pública conocida	Seguridad	**Crítico**	`getJwtSecret()` con fail-fast; sin fallback	§14
H2	El frontend hardcodea `https://conduit.productionready.io/api`	Configuración	Alto	URL por variable de entorno + proxy de nginx	§7
H3	Frontend con `react-scripts 1.1.1` (2018), sin lockfile: build no reproducible	Mantenibilidad	Alto	Reescritura con Vite 5 + lockfile	§7/§8
H4	El upstream no trae Dockerfile ni compose utilizable	Despliegue	Alto	Imágenes multi-stage + compose	§4/§7
H5	Sin réplica, sin backups, sin procedimiento de recuperación	Disponibilidad	Alto	Réplica streaming + backup verificado	§6/§15
H6	Sin observabilidad: no hay `/metrics` ni logs estructurados	Operación	Alto	Prometheus + exporters + dashboards	§10
H7	Índices solo los implícitos del ORM; ninguna estrategia de consultas	Rendimiento	Medio	8 consultas medidas antes/después	§5
H8	Esquema sin migraciones versionadas (depende de `db push`)	Mantenibilidad	Medio	`db/init/*.sql` versionado en el repo	§4
H9	Sin tests de integración contra una base real	Calidad	Medio	Suite de humo + CI con DB de servicio	§8
H10	Credenciales en variables de entorno sin rotación documentada	Seguridad	Medio	`.env` fuera del repo + rotación + gitleaks	§3/§14
H11	Sin límites de recursos ni healthchecks en contenedores	Operación	Bajo	`healthcheck` y límites por servicio	§4/§10
H12	`log_connections=off`: sin rastro de accesos a la base	Auditoría	Bajo	Se documenta como decisión consciente de rendimiento	§14

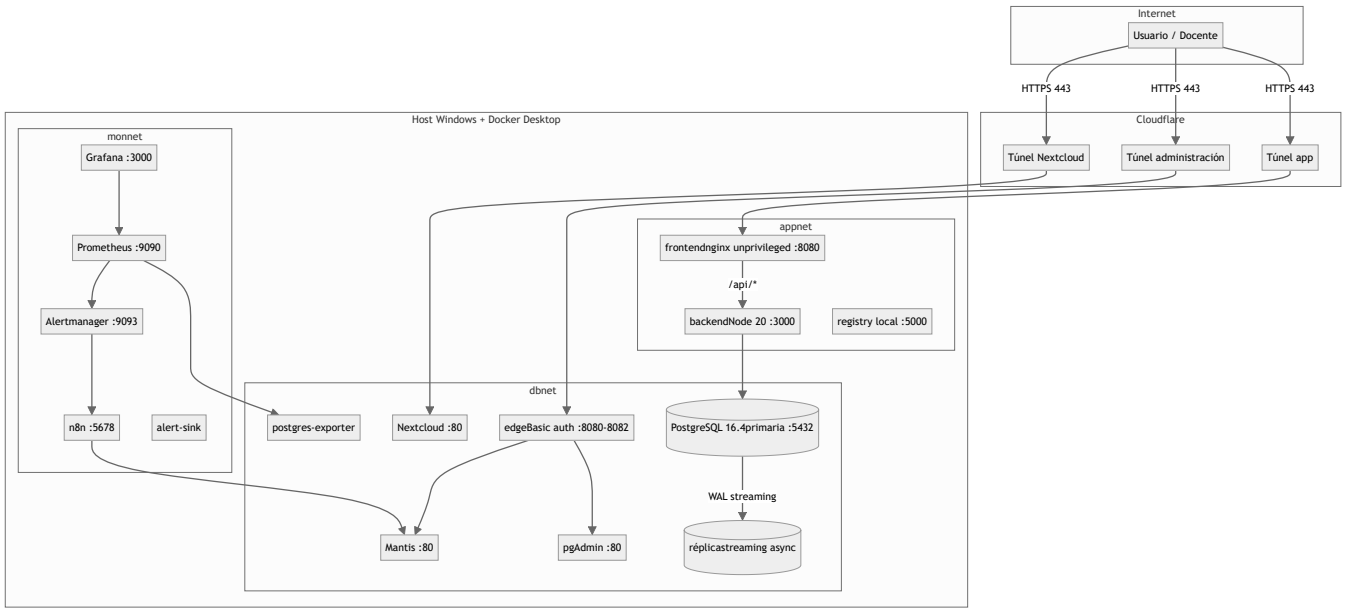
6. Evidencia

Evidencia	Archivo
Procedencia y commit del código heredado	`app/UPSTREAM.txt`
Inventario de versiones	`docs/informe/03-inventario-tecnologico.md`
Diagrama de arquitectura	`docs/02-arquitectura.md`
Decisiones sobre el frontend	`docs/05-decisiones.md` D-18

02 — Arquitectura general

Este documento describe **lo que está desplegado hoy**, no la arquitectura ideal. Cada componente de los diagramas existe en `compose.yaml` y se puede verificar con `docker compose ps`.

1. Vista de despliegue



Cinco contenedores de aplicación (`frontend`, `backend`, `db`, `db-replica`, `pgadmin`) y ocho de operación (`mantis`, `nextcloud`, `prometheus`, `alertmanager`, `grafana`, `n8n`, `edge`, `registry`), más cuatro exporters. Todos los puertos publicados están en `127.0.0.1`.

2. Componentes y responsabilidades

Componente	Responsabilidad	Tecnología	Puerto
`frontend`	SPA; sirve estático y proxea `/api` al backend	Vite 5 + React 18 → nginx 1.27 unprivileged	`127.0.0.1:8090`
`backend`	API REST del dominio; JWT; healthcheck con ping a la base	Node 20 + Express 4 + Prisma 4	ninguno (`expose 3000`)
`db`	Persistencia y origen de la replicación	PostgreSQL 16.4	`127.0.0.1:5433`
`db-replica`	Réplica de solo lectura por streaming asíncrono	PostgreSQL 16.4	ninguno
`pgadmin`	Administración de la base	pgAdmin 8	`127.0.0.1:8080`
`mantis`	Gestión de incidencias (§11)	MantisBT 2.28.4 sobre PostgreSQL	`127.0.0.1:8081`
`nextcloud`	Gestión documental con permisos por grupo (§12)	Nextcloud 30 sobre PostgreSQL	`127.0.0.1:8082`
`prometheus`	Recolección y evaluación de reglas	Prometheus 2.54	`127.0.0.1:9090`
`alertmanager`	Agrupación, silencios y envío a n8n	Alertmanager 0.27	`127.0.0.1:9093`
`grafana`	8 paneles de observabilidad	Grafana 11	`127.0.0.1:3001`
`n8n`	Automatización: alerta → incidencia	n8n 1.68	`127.0.0.1:5678`
`edge`	Borde con Basic auth para las herramientas administrativas	nginx 1.27	`127.0.0.1:8088-8091`
`registry`	Plan B de imágenes (si GHCR no está disponible)	registry 2	`127.0.0.1:5000`

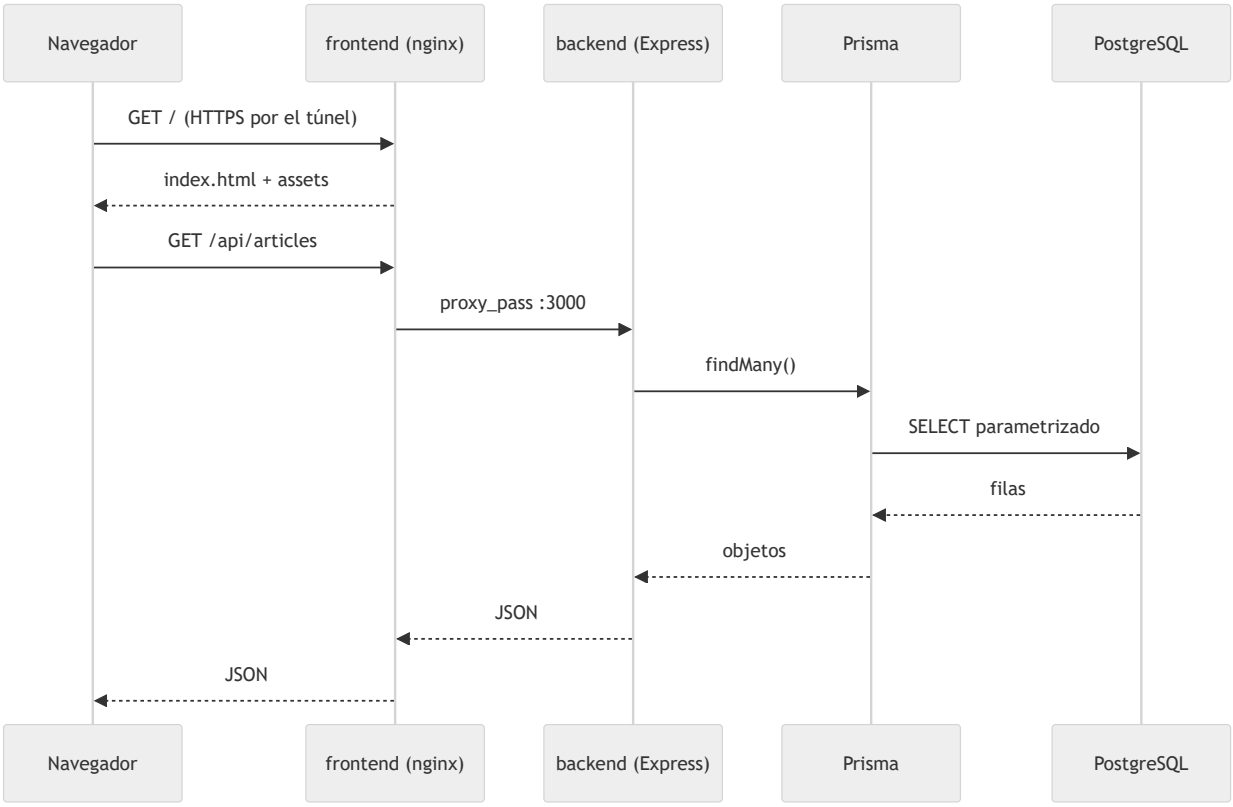
3. Redes y exposición

Servicio	Redes	Puerto publicado	Justificación
`frontend`	`appnet`	`127.0.0.1:8090`	único punto de entrada de la app
`backend`	`appnet`, `dbnet`	**ninguno** (`expose 3000`)	solo alcanzable desde el frontend
`db`	`dbnet`	`127.0.0.1:5433`	acceso local para desarrollo; en prod no se publica
`db-replica`	`dbnet`	**ninguno**	solo lectura, sin exposición
`pgadmin`	`dbnet`	`127.0.0.1:8080`	administración, jamás expuesta a Internet
`mantis`	`dbnet`	`127.0.0.1:8081`	perfil `ops`; acceso por el borde
`nextcloud`	`dbnet`	`127.0.0.1:8082`	perfil `ops`; túnel directo (login propio)
`prometheus`	`monnet`, `appnet`, `dbnet`	`127.0.0.1:9090`	necesita scrapear exporters de las tres redes
`n8n`	`appnet`, `dbnet`, `monnet`	`127.0.0.1:5678`	recibe webhooks y escribe en Mantis y en su base

Las tres redes están aisladas entre sí: `appnet` no ve la base, `monnet` solo se cruza con las otras para scrapear. `dbnet` **no** tiene `internal: true` porque el contenedor necesita resolver el DNS de Docker y salir a Internet para `apt` / `npm` durante el build (decisión D-15).

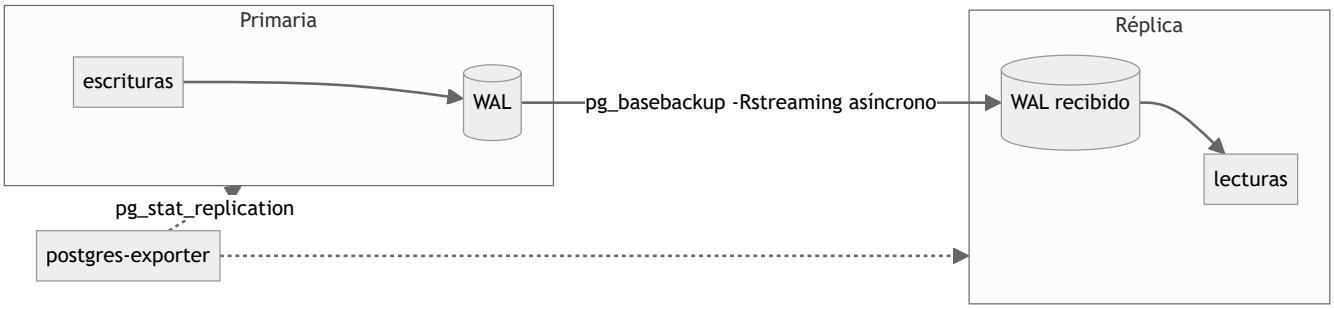
Todas las publicaciones son en **loopback**: no hay un solo puerto escuchando en `0.0.0.0`.

4. Flujo de una petición



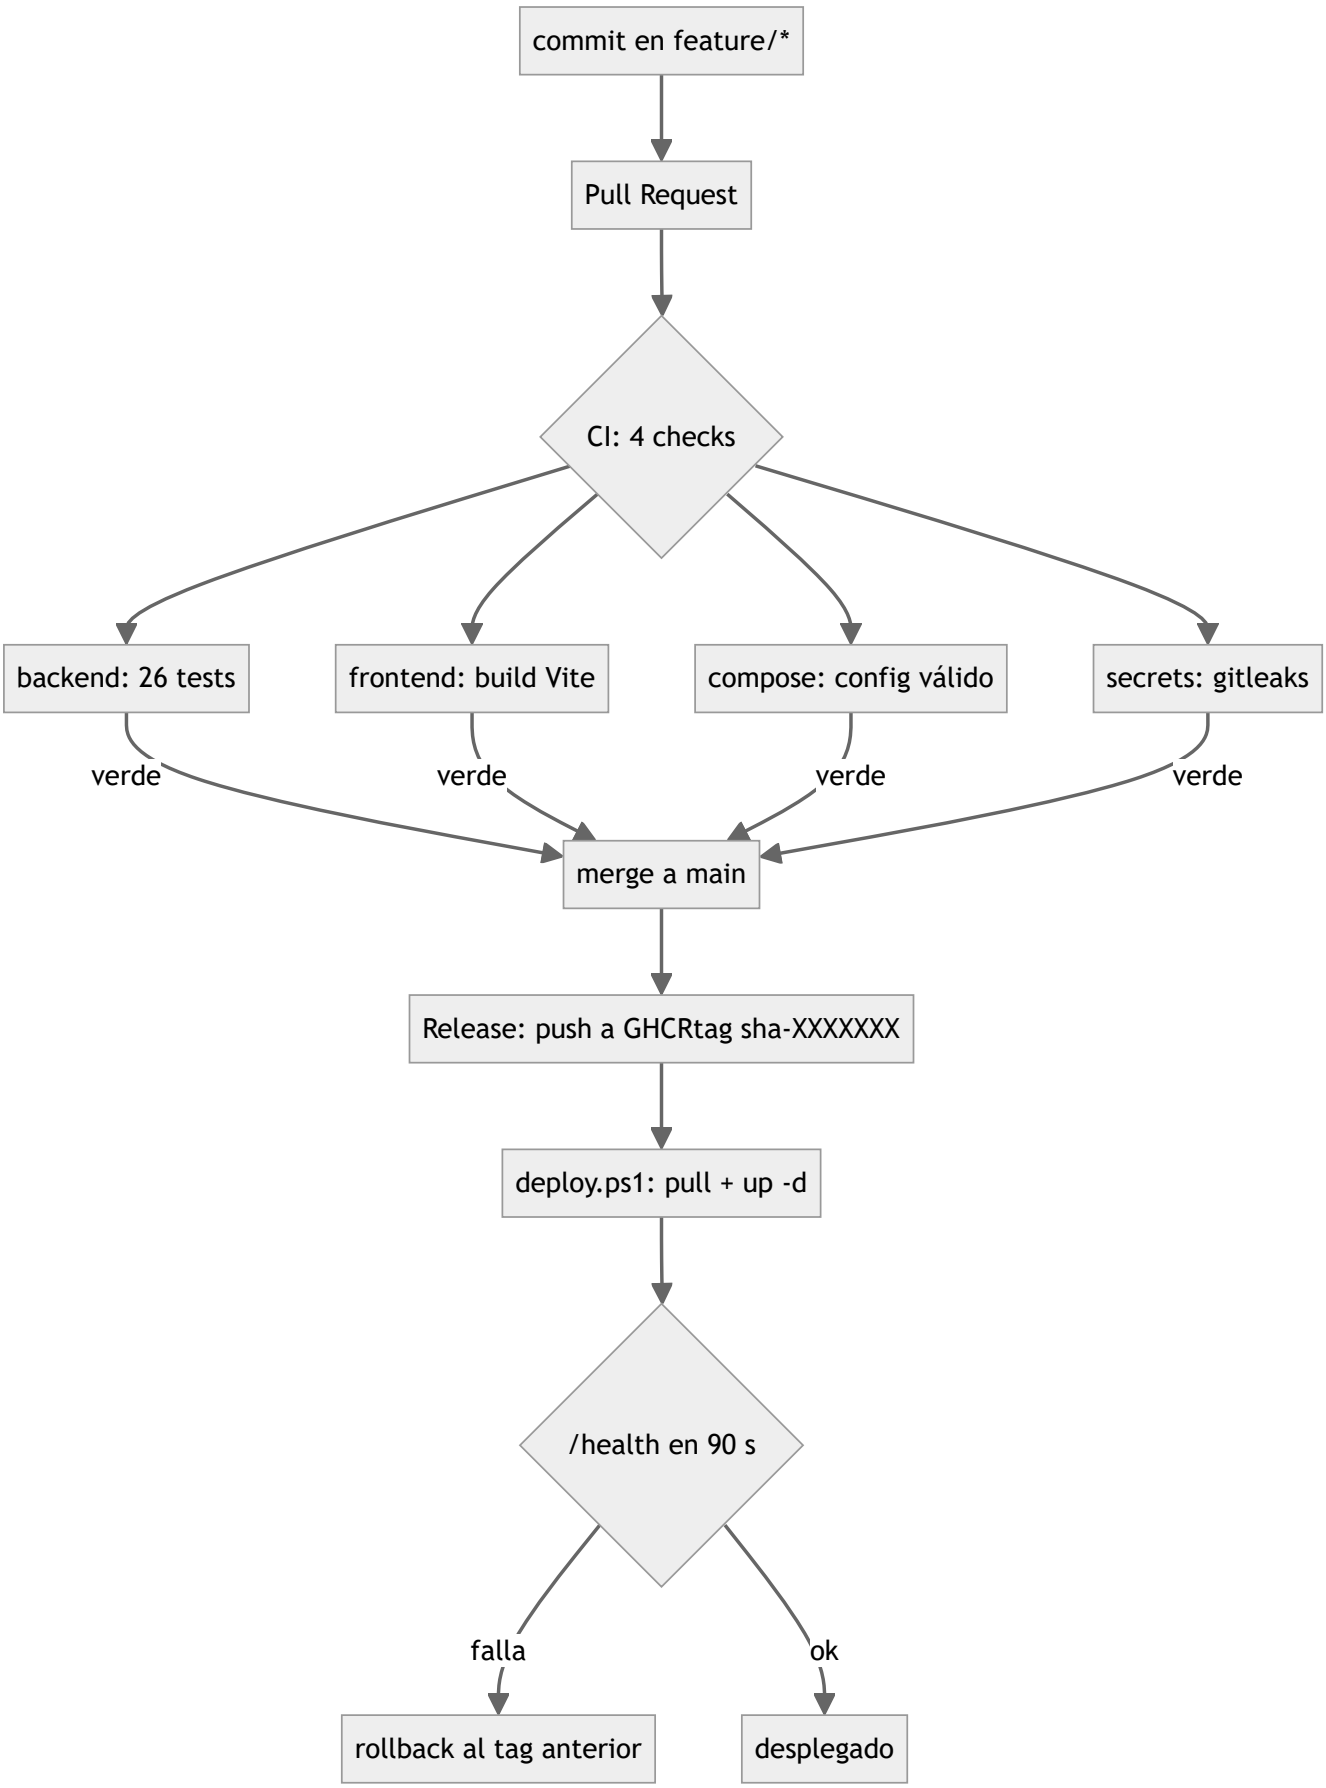
Un solo origen ⇒ **no hace falta CORS** (el `cors()` del backend queda como red de seguridad para clientes externos, no como solución de arquitectura). El frontend agrega las cabeceras de seguridad y el rate limit de `/api/` antes de llegar al backend.

5. Replicación



- Método: **streaming replication asíncrona** con `pg_basebackup -R`.
- `synchronous_commit=on` en la primaria: se prioriza integridad sobre latencia.
- **No hay failover automático.** Sin Patroni/repmgr nada se promueve solo. La promoción es manual, documentada y medida: **RTO 8,6 s** (§8).
- Métricas: `pg_stat_replication` (lag en bytes) y `pg_last_wal_replay_lsn()`.

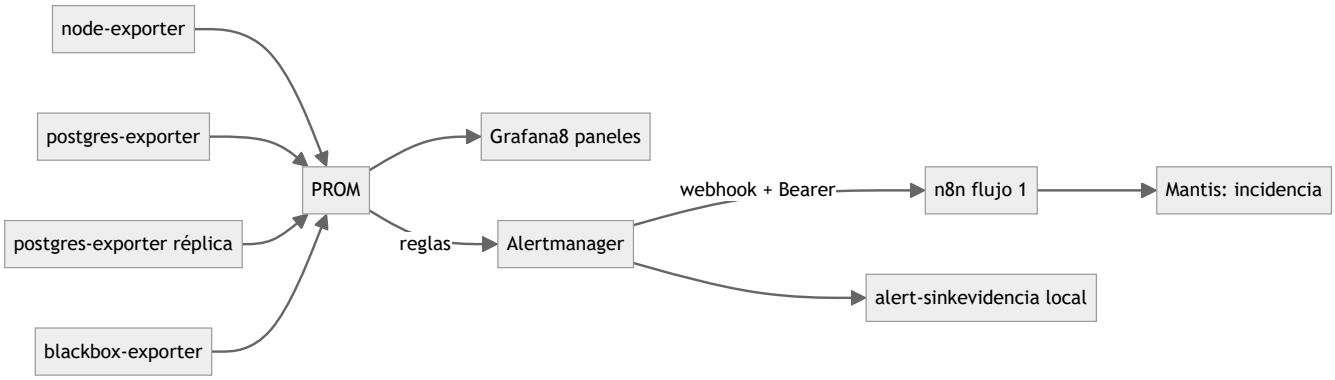
6. CI/CD



`main` está protegida con los 4 checks en modo estricto y `enforce_admins`. El deploy es **pull-based**: el host baja la imagen de GHCR y verifica `/health`; si no responde, vuelve sola al tag anterior (`.deploy/state.json` guarda el

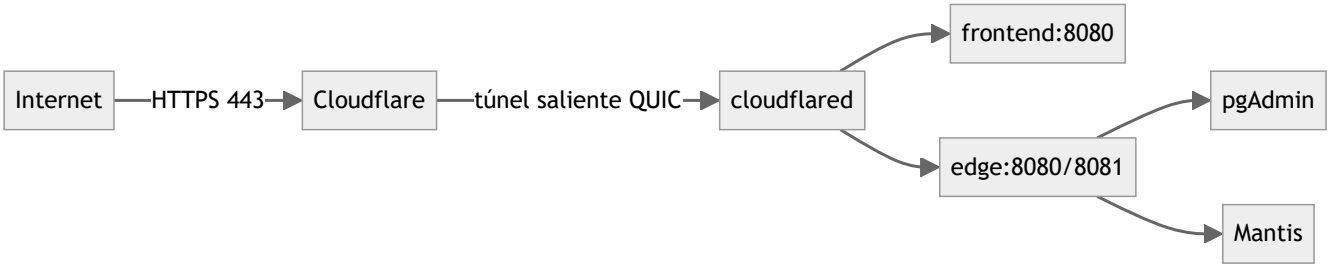
historial).

7. Monitoreo y alertas



Reglas activas: `ServicioCaido` (2 min), `CPUAlta` (85%, 5 min), `MemoriaAlta` (90%, 5 min), `DiscoCasiLleno`, `PostgresCaido` (1 min) y `ReplicacionAtrasada` (2 min). El flujo 1 está probado de punta a punta: alerta real → incidencia #18 en Mantis.

8. Publicación en Internet



El host **no abre puertos**: el túnel es saliente. El TLS lo termina Cloudflare. Las herramientas administrativas quedan detrás de HTTP Basic en `edge`, y además tienen su propio login.

Servicio	Ruta pública	Autenticación
Aplicación	`https://<random>.trycloudflare.com`	login propio (JWT)
pgAdmin	`https://<random>.trycloudflare.com`	Basic auth + login de pgAdmin
Mantis	`https://<random>.trycloudflare.com`	Basic auth + login de Mantis

9. Decisiones estructurales

Decisión	Motivo	Registro
Backend sin puerto publicado	reduce superficie; el frontend es el único borde	D-08
Redes separadas `appnet` / `dbnet` / `monnet`	el frontend no debe hablar con la base	§7
Healthcheck con `SELECT 1`	un contenedor "up" con la base caída no es un servicio sano	§7
Imágenes multi-stage	la imagen final no lleva toolchain ni devDependencies	§14
Frontend unprivileged (uid 101, :8080)	un proceso comprometido no corre como root	§14
Mantis en perfil `ops`	no compite por recursos con la demo principal	D-21
Un solo motor (PostgreSQL)	menos superficie y menos servicios que mantener	D-03/D-21
Failover manual	Patroni exige 3 nodos; se declara y se mide	D-04

10. Estado actual

Todo lo planificado para §6, §7, §9, §10, §12 y §13 está desplegado y verificado. Lo que no está:

- **Flujos 2 y 3 de n8n**: el 2 necesita una imagen con `postgresql-client`; el 3 está implementado pero no programado (ver `13-automatizacion.md`).
- **Failover automático**: fuera de alcance por diseño (D-04).

03 — Inventario tecnológico

Versiones efectivamente usadas (no "la última que había"). Las de runtime están fijadas en los Dockerfile o en el compose; las de dependencias, en `package-lock.json`.

Backend

Componente	Versión	Rol	Nota
Node.js	20 (imagen `node:20-alpine`)	runtime	LTS; el host tiene Node 26, que no se usa para el build
Express	~4.18.1	framework HTTP	
Prisma Client	^4.16.1	ORM	`provider = postgresql`
jsonwebtoken	^9.0.2	firma de JWT	`HS256`, expiración 60 días
express-jwt	^8.4.1	middleware de auth	
bcryptjs	^2.4.3	hash de contraseñas	
slugify	^1.6.0	slugs de artículos	
Nx	17.2.6	build del monorepo	build reproducible vía `package-lock.json`

Frontend (reescrito, D-18)

Componente	Versión	Rol
React / React DOM	^18.3.1	UI
Vite	^5.4.8	build y dev server
react-router-dom	^6.26.2	ruteo SPA
nginx	1.27-alpine	servidor estático + proxy `/api`

Base de datos

Componente	Versión	Nota
PostgreSQL	16.4-alpine	primaria; réplica en §6
pg_stat_statements	extensión incluida	requiere `shared_preload_libraries`
pg_buffercache	extensión incluida	inspección de caché
pgAdmin	8 (`dpage/pgadmin4:8`)	administración, solo loopback
pgBadger	a definir en §4	análisis de logs

Infraestructura

Componente	Versión	Nota
Docker Engine	29.9.3	Docker Desktop sobre WSL2
Docker Compose	v5.7.0	`compose.yaml`
Windows	11	host de desarrollo
WSL2 / Ubuntu	2	backend de Docker

Servicios previstos (§10, §11, §12, §13)

Componente	Imagen prevista	Estado
Prometheus	`prom/prometheus`	pendiente
Grafana	`grafana/grafana`	pendiente
node-exporter	`prom/node-exporter`	pendiente
cAdvisor	`gcr.io/cadvisor/cadvisor`	pendiente
postgres-exporter	`prometheuscommunity/postgres-exporter`	pendiente
blackbox-exporter	`prom/blackbox-exporter`	pendiente
Alertmanager	`prom/alertmanager`	pendiente
n8n	`n8nio/n8n`	pendiente
Mantis	a definir (soporte PostgreSQL a verificar)	pendiente
Nextcloud	`nextcloud`	pendiente

Eventos de ciberseguridad considerados al elegir el stack

El enunciado pide explícitamente tener en cuenta los últimos eventos al inventariar el stack.

Evento	Qué fue	Impacto en nuestras decisiones
CVE-2024-4577 (PHP-CGI, Windows)	inyección de argumentos explotada masivamente para ransomware	descarta stacks PHP para los servicios propios; Mantis (PHP) queda aislado y sin exposición pública
GhostAction (sep. 2025)	robo de secretos desde workflows de GitHub Actions en ~327 repos	secretos solo en GitHub Secrets + `gitleaks` en pre-commit y CI (§3/§8)
xz-utils / backdoor en cadena de suministro (2024)	puerta trasera en una dependencia de compresión	imágenes con tag fijo, sin `latest`; escaneo con Trivy (§14)
Compromisos de paquetes npm/PyPI (recurrentes)	malware en dependencias publicadas	lockfile obligatorio y `npm audit` en el pipeline
EOL de Node 8/16 y `react-scripts` antiguo	runtimes sin parches	se fija Node 20 y se reescribe el frontend (D-18)

> Verificar con la cátedra cuál evento espera ver citado en el inventario; el informe final debe nombrar el mismo en §1 y en §14 para no contradecirse.

Evidencia

Evidencia	Archivo
Versiones de runtime	`compose.yaml`, `app/*/Dockerfile`
Versiones de dependencias	`app/backend/package-lock.json`, `app/frontend/package.json`
Versión del motor	`docker compose exec db psql -c 'select version();'` → `evidence/04/version-motor.txt`

04 — Manual de instalación

1. Objetivo

Levantar el stack completo desde cero en una máquina Windows con Docker Desktop, sin pasos implícitos. Todo lo que sigue está probado en el equipo de la práctica; los tiempos son los medidos, no estimaciones.

2. Requisitos

Componente	Versión mínima	Verificación
Windows	11 (probado)	`winver`
Docker Desktop	4.30+ con WSL 2	`docker version`
PowerShell	5.1 (probado) o 7.x	`$PSVersionTable`
Git	cualquiera reciente	`git --version`
Espacio en disco	**40 GB libres**	8,5 GB de base + imágenes + backups
RAM	8 GB (16 GB recomendado)	Docker Desktop → Resources
Python	3.11+ (solo scripts auxiliares)	`python --version`

Recursos asignados a Docker Desktop usados en las pruebas: **6 CPU, 8 GB de RAM, 60 GB de disco**. Con menos de 4 GB de RAM la carga del dataset puede quedar sin memoria.

3. Instalación paso a paso

Paso 1 — Clonar y entrar al repositorio

```
git clone https://github.com/TomasGudi/HIA-2026.git
cd HIA-2026
git checkout main
```

Paso 2 — Crear el `.env`

```
Copy-Item .env.example .env
```

Editar `.env` y **cambiar todas** las contraseñas. Las que no son opcionales:

Variable	Para qué	Regla
`POSTGRES_PASSWORD`	usuario administrador de la base	≥ 16 caracteres
`APP_DB_PASSWORD`	rol `app` de la aplicación (solo DML)	≥ 16 caracteres
`REPL_PASSWORD`	replicación	≥ 16 caracteres
`JWT_SECRET`	firma de sesiones	**≥ 32 caracteres**
`MANTIS_CRYPTO_SALT`	cifrado interno de Mantis	≥ 32 caracteres
`MANTIS_API_TOKEN`	token de la API de Mantis	**exactamente 32 caracteres**
`N8N_WEBHOOK_TOKEN`	autenticación del webhook	≥ 32 caracteres
`EDGE_ADMIN_PASSWORD`	Basic auth del borde administrativo	≥ 16 caracteres

Generar valores aleatorios:

```
python -c "import secrets; print(secrets.token_urlsafe(24))"
```

> `MANTIS_API_TOKEN` es la única con longitud fija: Mantis rechaza tokens que no tengan 32 caracteres. Si se cambia, hay que regenerarlo también en la UI de Mantis.

Paso 3 — Base de datos

```
docker compose up -d db pgadmin
docker compose ps
```

Esperar a que `db` esté `healthy` (healthcheck con `pg_isready`). El primer arranque ejecuta `db/init/` en orden: esquema, extensiones, usuario de monitoreo, usuario de replicación y rol `app` con privilegios mínimos.

Paso 4 — Cargar el dataset

```
./scripts/db.ps1 seed       # ~13 min: 24,2 M de filas
./scripts/db.ps1 indexes    # DESPUÉS de la carga, no antes
./scripts/db.ps1 stats
```

Los índices se crean **después** de la carga a propósito: crearlos antes multiplica el tiempo de inserción sin mejorar nada. `stats` debe mostrar las tablas de volumen con 6.000.001 filas.

Paso 5 — Aplicación

```
docker compose up -d backend frontend
curl.exe http://127.0.0.1:8090/health
```

Respuesta esperada: `{"status":"ok","db":"up","version":"dev"}`.

Paso 6 — Réplica (opcional para desarrollo, obligatoria para §6)

```
docker compose up -d db-replica
./scripts/replica.ps1 status    # debe mostrar state=streaming
./scripts/replica.ps1 test      # escritura en primaria + lectura en réplica
```

Paso 7 — Servicios de operación

```
docker compose --profile ops up -d
```

Levanta Mantis, Prometheus, Alertmanager, Grafana, exporters, n8n, el borde administrativo y el registro local. Sin `--profile ops` el stack queda en modo mínimo (solo app + base).

Paso 8 — Verificación integral

```
./scripts/monitoreo.ps1 status
./scripts/publicar.ps1 up
```

`publicar.ps1` imprime las URLs de los túneles. Son **efímeras**: cambian en cada arranque.

4. Verificación

Qué	Comando	Resultado esperado
Contenedores	`docker compose ps`	todos `healthy` o `running`

Qué	Comando	Resultado esperado
Salud de la app	`curl.exe http://127.0.0.1:8090/health`	`status=ok` , `db=up`
Datos	`./scripts/db.ps1 stats`	6.000.001 filas en tablas de volumen
Réplica	`./scripts/replica.ps1 status`	`streaming` , lag < 1 s
Monitoreo	`http://127.0.0.1:9090/targets`	todos los targets `UP`
Grafana	`http://127.0.0.1:3001`	8 paneles con datos
Mantis	`http://127.0.0.1:8081`	login y proyecto `HIA-2026`
n8n	`http://127.0.0.1:5678`	flujo `01-alerta-a-mantis` activo

5. Puertos publicados

Todos en `127.0.0.1` : nada se expone a la LAN.

Puerto	Servicio	Nota
5433	PostgreSQL primaria	5432 queda libre para una instalación local
8080	pgAdmin	
8081	Mantis	
8090	Frontend	proxy a `/api/` del backend
3001	Grafana	
5000	Registro local de imágenes	plan B de GHCR
5678	n8n	
8088 / 8089 / 8091	Borde administrativo	pgAdmin / Mantis / n8n con Basic auth
9090 / 9093	Prometheus / Alertmanager	

6. Problemas frecuentes

Síntoma	Causa	Solución
`db` reinicia en bucle	contraseña con `$` o `#` sin escapar en `.env`	usar `secrets.token_urlsafe` (sin esos caracteres)
`frontend` unhealthy	el contenedor escucha en 8080, no en 80	verificar `docker port pi-frontend` → `8080/tcp`
`seed` termina sin filas	volumen ya inicializado con otro esquema	`./scripts/db.ps1 reset` (borra datos)
Réplica no arranca	`pg_basebackup` falló por contraseña	`./scripts/replica.ps1 reinit`
Mantis da 500	`MANTIS_CRYPTO_SALT` cambió después de inicializar	restaurar el valor original o recrear el volumen
n8n no importa el flujo	la base `n8n` ya tenía workflows	el entrypoint solo importa si la tabla está vacía
`deploy.ps1` falla al bajar la imagen	GHCR privado o sin login	usar `-Registry 127.0.0.1:5000` con el registro local

7. Tiempos medidos

Etapa	Tiempo
`docker compose up -d db pgadmin` (primer arranque)	~40 s
`db.ps1 seed` (24,2 M de filas)	~13 min

Etapa	Tiempo
`db.ps1 indexes`	~2 min
`docker compose --profile ops up -d`	~90 s
Stack completo desde cero	**~18 min**

8. Decisiones

- **Un solo `compose.yaml` con perfiles** en vez de varios archivos: `ops` separa lo que es operación de lo que es la aplicación. Ver `docs/05-decisiones.md` (D-03, D-16).
- **Sin `docker-compose.override.yml`**: lo que se prueba es lo que se despliega.
- **Secretos solo en `.env`**: el repo tiene `.env.example` con placeholders y gitleaks en CI.

9. Limitaciones

- El manual asume Windows + Docker Desktop. En Linux los comandos son los mismos salvo `curl.exe` → `curl` y las rutas de los scripts.
- No se cubre un clúster real: la réplica es un contenedor en el mismo host, no otra máquina.
- La publicación usa túneles rápidos de Cloudflare (URL efímera), no un dominio propio.

10. Preguntas frecuentes

¿Por qué la base no publica el 5432? Porque el 5432 suele estar ocupado por un PostgreSQL local y porque publicar el puerto estándar invita a escaneos. Se usa 5433 y solo en loopback.

¿Qué pasa si corro `docker compose down -v`? Se borra el volumen `pi-pgdata`: hay que repetir el paso 4 (~15 min). Sin `-v`, los datos sobreviven; está probado en `evidence/04/persistencia.txt`.

¿Se puede levantar sin la réplica ni el monitoreo? Sí. `docker compose up -d` levanta solo app y base. La réplica y `--profile ops` son necesarios para §6 y §10, no para que la aplicación funcione.

05 — Configuración Docker

1. Servicios

Servicio	Imagen	Puertos publicados	Redes	Perfil
`db`	`postgres:16.4-alpine`	`127.0.0.1:5433`	`dbnet`	—
`pgadmin`	`dpage/pgadmin4:8`	`127.0.0.1:8080`	`dbnet`	—
`backend`	build `./app/backend`	— (solo `expose 3000`)	`appnet`, `dbnet`	—
`frontend`	build `./app/frontend`	`127.0.0.1:8090`	`appnet`	—
`mantis`	build `./app/mantis`	`127.0.0.1:8081`	`dbnet`	`ops`
`nextcloud`	`nextcloud:30-apache`	`127.0.0.1:8082`	`dbnet`	`ops`

Regla transversal: **ningún puerto se publica fuera de** `127.0.0.1`. La publicación a Internet es por túnel (§9), no abriendo puertos.

2. Redes

Red	Para qué	Quién está
`pi-appnet`	tráfico de la aplicación	`frontend` ↔ `backend`
`pi-dbnet`	tráfico de datos	`backend`, `db`, `pgadmin`, `mantis`

El frontend **no** está en `dbnet`: no tiene por qué hablar con la base. Es segmentación real, no un dibujo.

> **Aprendizaje (D-15)**: la primera versión declaraba `dbnet` como `internal: true`. Docker entonces **descarta silenciosamente** la publicación de puertos: `docker compose up` sale en verde, los contenedores están sanos, y `docker port` no muestra nada. Se detectó probando con un `nginx` aislado sobre la misma red.

3. Volúmenes

Volumen	Contenido	Consecuencia de perderlo
`pi-pgdata`	datos de PostgreSQL	se regenera con `scripts/db.ps1 seed` (~13 min)
`pi-pgadmin`	configuración de pgAdmin	se reconfigura
`pi-mantis-files`	adjuntos de las incidencias	**se pierde la evidencia de §11**

4. Imágenes

Backend (`app/backend/Dockerfile`)

- Etapa `build`: `node:20` + `npm ci` + `prisma generate` + `nx build`.
- Etapa `runtime`: `node:20-slim` + OpenSSL (lo necesita Prisma) + **solo dependencias de producción** (`npm ci --omit=dev` sobre el `package.json` que genera Nx).
- Corre como usuario `node` (no root).
- Healthcheck propio contra `/health`, que hace un `SELECT 1` a la base: un contenedor "up" con la base caída no es un servicio sano.

Detalle que costó: el schema de Prisma está en `src/prisma/schema.prisma`, fuera de la ubicación por defecto, así que el `postinstall` de `@prisma/client` **no** lo detecta. Hay que ejecutar `npx prisma generate --schema=...` explícito en el build, y copiar `node_modules/.prisma` y `node_modules/@prisma` a la imagen final.

Frontend (`app/frontend/Dockerfile`)

- Etapa `build` : `node:20` + `npm ci` + `vite build` .
- Etapa `runtime` : `nginx:1.27-alpine` sirviendo estático (**74 MB**, sin Node adentro).
- `nginx.conf` : SPA fallback, `/healthz` , proxy `/api` → `http://backend:3000` (mismo origen, sin CORS abierto) y caché de assets con hash.

5. Variables de entorno

Todo por `.env` (nunca versionado) y `.env.example` con placeholders.

Variable	Uso
`POSTGRES_*`	base principal
`DB_PORT`	puerto publicado (5433 por colisión con otro stack local, D-16)
`JWT_SECRET`	firma de tokens; obligatorio (sin fallback, H1)
`MANTIS_*`	base, rol, contraseña del admin y `crypto_master_salt`
`SEED_*`	volumen del dataset

Dentro de la red Docker la base se resuelve como `db:5432` ; el 5433 es solo el puerto del host.

6. Verificación (evidencia)

Comprobación	Resultado
`docker compose config --quiet`	válido
`docker compose ps`	5 servicios, 3 con healthcheck en `healthy`
`GET :3000/health` desde el contenedor	`{"status":"ok","db":"up"}`
`GET :8090/`	200 (SPA)
`GET :8090/api/articles?limit=3`	200, `articlesCount = 6.000.000`
Escritura completa (registro → alta → comentario)	201 / 201 / 200

Detalle en `evidence/07/e2e.log` .

7. Limitaciones

- El listado público tarda **10,4 s**: es el objetivo principal de §5 (hoy el `count(*)` con `JOIN` sobre 6M de filas domina el tiempo).
- No hay límites de CPU/memoria por servicio (`deploy.resources`) todavía: se agregan en §10 para que las métricas de cAdvisor sean comparables.
- `frontend` y `backend` se construyen localmente; la publicación en registry llega en §8.

06 — Migración y carga de datos

1. Objetivo

Poblar PostgreSQL con un dataset **sintético** que permita medir rendimiento real (§5), probar replicación (§6) y ejercitar la aplicación con volumen representativo, sin usar datos personales reales.

2. Método

Aspecto	Decisión
Generación	`generate_series` + aritmética modular (sin `random()`) → **determinista y reproducible** (D-17)
Formato	SQL puro (`db/seed/10-seed.sql` para carga completa, `11-seed-bulk.sql` para recargar solo tablas de relación)
Integridad	FKs declaradas; durante la carga se desactivan los triggers (`session_replication_role=replica`) y se validan después (D-19)
Índices	**no** existen durante la carga; se crean al final (D-14)
Restricciones	PK, UNIQUE (`email` , `username` , `slug` , `name`), UNIQUE `(A,B)` en las N:M, CHECK de auto-seguimiento
Datos personales	ninguno: emails `userN@example.com` , contraseñas con hash ficticio, textos Lorem ipsum

Volumen por tabla

Tabla	Filas	Rol en el dataset
`Article`	6.000.000	tabla de volumen
`Comment`	6.000.000	tabla de volumen
`_UserFavorites`	6.000.000	tabla de volumen (N:M)
`_ArticleToTag`	6.000.000	relación N:M derivada de los artículos
`User`	200.000	catálogo con cardinalidad realista
`Tag`	5.000	catálogo
Total	**24.205.000**	

> El enunciado pide "al menos 6.000.000 de registros por tabla de datos que forme parte del conjunto de prueba". Se interpreta como **tablas de volumen del dominio** (ver D-05); los catálogos se dimensionan con cardinalidad realista porque inflarlos no aporta nada al análisis.

3. Tiempos medidos

Etapa	Filas	Tiempo
`User`	200.000	1,9 s
`Tag`	5.000	0,02 s
`Article`	6.000.000	**10 min 43 s**
`Comment` (6 trozos de 1M)	6.000.000	**26,0 s** (3,8 + 4,3 + 4,4 + 4,9 + 5,0 + 5,1)
`_UserFavorites`	6.000.000	24,6 s
`_ArticleToTag`	6.000.000	29,9 s
`ANALYZE`	—	36,1 s

Etapa	Filas	Tiempo
Total	24,2M	**~13 min**

Evidencia: `evidence/04/seed-carga.log`, `evidence/04/seed-bulk.log`.

Por qué `Article` tarda 20× más que `Comment` con la misma cantidad de filas

`Article` tiene dos índices UNIQUE (`slug`, y la PK), un cuerpo de ~500 bytes por fila (`repeat(...)` ×12) y una FK a `User`; además se cargó **antes** de ajustar `max_wal_size`. `Comment` se cargó sin triggers de FK y con el clúster ya ajustado. Es una comparación honesta del costo de mantener índices y WAL durante la carga, y se retoma en §5.

4. Tamaño final

Tabla	Datos	Índices	Total
`Article`	5.210 MB	722 MB	**5.931 MB**
`Comment`	721 MB	301 MB	1.021 MB
`_UserFavorites`	207 MB	266 MB	473 MB
`_ArticleToTag`	207 MB	168 MB	375 MB
`User`	36 MB	28 MB	64 MB
`Tag`	264 kB	304 kB	568 kB
Base de datos			**7.874 MB (7,9 GB)**

Los índices ocupan **~1,5 GB (19 % de la base)**. Ese número es el que hay que justificar cada vez que se propone un índice nuevo (§5): no es gratis ni en disco ni en escritura. Evidencia: `evidence/04/volumen.txt`.

5. Incidente de carga y su resolución (D-19)

Síntoma	La inserción de `Comment` quedó 30 min con menos de 1.000 filas cargadas
Causa	Trigger de FK: `SELECT 1 FROM "User" WHERE id = $1 FOR KEY SHARE` por fila; 6M comentarios contra 200k usuarios → contención de locks de fila
Solución	`SET session_replication_role = replica` durante la carga + validación posterior de huérfanos
Resultado	6M de comentarios en 26 s (mejora de más de dos órdenes de magnitud)
Trade-off	La integridad deja de estar garantizada por el motor durante la carga; se garantiza por verificación explícita y se documenta

6. Verificación de integridad (evidencia)

Ejecutada al final de la carga, sobre 24M de filas:

Control	Huérfanos
comentarios huérfanos (artículo)	**0**
comentarios huérfanos (autor)	**0**
favoritos huérfanos	**0**
artículo-etiqueta huérfanos	**0**

Evidencia: `evidence/04/seed-bulk.log` (bloque "VERIFICACION DE INTEGRIDAD").

Dato extra que sirve para §5

La misma consulta de control de huérfanos tardó **235.324 ms (3 min 55 s) sin índices** y **3.570 ms con** `Comment_articleId_idx`: 65× menos. No es una consulta del producto, pero demuestra el efecto de un índice sobre un

`LEFT JOIN` de 6M × 6M.

7. Parámetros ajustados para la carga (D-20)

Parámetro	Antes	Después	Motivo
`max_wal_size`	1 GB (default)	8 GB	la primera carga generó **38 GB de WAL** por checkpoints frecuentes
`checkpoint_timeout`	5 min (default)	15 min	menos full-page writes
`synchronous_commit`	on	off (solo durante la carga)	durabilidad no crítica en datos regenerables
`maintenance_work_mem`	64 MB	1 GB (sesión de carga)	`ANALYZE` y creación de índices más rápidos

Los dos primeros se aplicaron con `ALTER SYSTEM` + `pg_reload_conf()` (sin reinicio) y quedan en `postgresql.auto.conf`; se revierten o se justifican en el informe de §5.

8. Reproducción

```
docker compose up -d db
./scripts/db.ps1 seed      # carga completa (10-seed.sql)
./scripts/db.ps1 indexes   # índices después de la carga
./scripts/db.ps1 stats     # tamaños y conteos
```

Para recargar solo comentarios/favoritos/relaciones:

```
docker compose exec -T db psql -U practica_app -d practica `
  -v articles=6000000 -v comments=6000000 -v favorites=6000000 `
  -f /db/seed/11-seed-bulk.sql
```

9. Limitaciones

- `Article.body` es texto repetido: la distribución de longitudes no es realista, así que las mediciones de `LIKE`/full-text son optimistas en tamaño pero válidas en forma.
- No hay `_UserFollows` cargado (0 filas): el feed de seguidos se probará con datos insertados a mano en §5 si hace falta.
- El dataset **no** se versiona en el repo (7,9 GB): se regenera con los scripts.

07 — Informe de optimización SQL

1. Método

1. Se identificaron las consultas con `pg_stat_statements` (top por tiempo total) y se contrastaron con las operaciones reales del backend (Prisma): cada consulta de este informe corresponde a una pantalla del producto, no a un ejemplo inventado.
2. Para cada una se capturó `EXPLAIN (ANALYZE, BUFFERS)` y el tiempo de ejecución con la caché caliente (segunda corrida).
3. Se aplicó **un cambio por vez**, midiendo el efecto.
4. Se probó también una optimización que **no** funcionó y se descartó con el número en la mano.

Scripts: `db/queries/10-baseline.sql` (antes) y `db/queries/20-optimizado.sql` (después). Evidencia cruda: `evidence/05/baseline-1.txt`, `evidence/05/optimizado.txt`, `evidence/05/control.txt`.

2. Resultado general

#	Consulta	Antes	Después	Mejora	Cambio aplicado
Q1	count del listado público	656 ms	**5,9 ms**	111×	conteo acotado (`LIMIT` interno)
Q2	listado paginado (offset 0)	5,3 ms	5,3 ms	—	ya óptimo (índice de `createdAt`)
Q2b	paginación profunda (offset 500.000)	1.933 ms	**62,6 ms**	31×	keyset pagination
Q3	listado filtrado por etiqueta	134 ms	134 ms	—	ya óptimo (nested loop con índices)
Q4	etiquetas populares (top 10)	1.033 ms	**0,69 ms**	1.497×	vista materializada
Q5	feed de autores seguidos	8.331 ms	**1,2 ms**	6.942×	reescritura `IN (subconsulta)`
Q6	detalle + comentarios	7,5 ms	7,5 ms	—	ya óptimo (índices únicos)
Q7	top de artículos por favoritos	3.565 ms	**1,4 ms**	2.546×	vista materializada
Q8	búsqueda por título (`ILIKE '%…%'`)	5.292 ms	**3,5 ms**	1.512×	`pg_trgm` + índice GIN

Efecto medido en el producto: `GET /api/articles` pasó de **7,9 s a 0,19 s** (41×).

3. Análisis consulta por consulta

Q1 — count del listado (656 ms → 5,9 ms)

Plan inicial: `Parallel Hash Join` + `Parallel Index Only Scan` sobre `Article_authorId_idx` (2.000.000 filas × 3 workers). El join no es el problema: **contar 6M de filas es O(n)** y ningún índice lo evita.

Decisión: acotar el conteo a 10.000 (la interfaz solo necesita la cantidad de páginas). El plan corta al alcanzar el tope y baja a 5,9 ms.

> Hallazgo mayor: la consulta que **genera Prisma** para este mismo caso tarda **17,8 s** de promedio (5 llamadas en `pg_stat_statements`), contra 656 ms del SQL equivalente escrito a mano. El ORM arma una subconsulta con `IN (SELECT … FROM "User" WHERE demo)` que el planificador resuelve mal. Se reemplazó por SQL directo en `article.service.ts` (ver §5 del informe de configuración Docker).

Q2 — listado paginado (5,3 ms, sin cambios)

Usa `Article_createdAt_idx` y corta en 10 filas. **No se tocó**: no hay nada que optimizar y agregar un índice acá solo costaría escrituras.

Q2b — paginación profunda (1.933 ms → 62,6 ms)

Con `OFFSET 500000` PostgreSQL lee y descarta medio millón de filas. Se reemplazó por **keyset pagination**: `WHERE (createdAt, id) < (último de la página anterior)`.

Trade-off honesto: keyset no permite "saltar a la página 50" directamente; sirve para scroll infinito o "siguiente/anterior", que es el patrón real de un listado.

Q3 — filtro por etiqueta (134 ms, sin cambios)

El plan ya es bueno: `Bitmap Index Scan` sobre `_ArticleToTag_B_idx` → `Index Scan` sobre `Article_pkey` → `Index Scan` sobre `User_pkey`, 1.200 filas y 9,5 ms de ejecución. Los 134 ms incluyen planificación y JIT de la primera ejecución. **Se deja como está** y se documenta: es el caso que demuestra que no todo se optimiza agregando índices.

Q4 — etiquetas populares (1.033 ms → 0,69 ms)

`GROUP BY` sobre 6M de filas de `_ArticleToTag` en cada request. Se materializó el agregado:

```
CREATE MATERIALIZED VIEW mv_tag_counts AS
SELECT t.id, t.name, count(*) AS n
FROM "_ArticleToTag" at JOIN "Tag" t ON t.id = at."B"
GROUP BY t.id, t.name;
```

Trade-off: el dato puede tener atraso. El refresco se delega a n8n (§13), que es exactamente el tipo de tarea operativa que pide el enunciado.

Q5 — feed de autores seguidos (8.331 ms → 1,2 ms)

El `JOIN "_UserFollows"` hacía que el planificador estimara mal y terminara escaneando artículos. Reescritura:

```
SELECT … FROM "Article" a
WHERE a."authorId" IN (SELECT "B" FROM "_UserFollows" WHERE "A" = 42)
ORDER BY a."createdAt" DESC LIMIT 10;
```

Plan nuevo: `Nested Loop` con `Index Only Scan` sobre `_UserFollows_AB_unique` y `Index Scan` sobre `Article_authorId_idx`. **0,109 ms de ejecución.**

Q6 — detalle + comentarios (7,5 ms, sin cambios)

`slug` es UNIQUE (índice), `Comment.articleId` está indexado y el subquery de conteo usa ese índice. Óptimo de entrada.

Q7 — top de artículos por favoritos (3.565 ms → 1,4 ms)

Mismo patrón que Q4: agregado sobre 6M. Vista materializada `mv_article_favorites` con índice único y otro por `favs DESC`.

Q8 — búsqueda por título (5.292 ms → 3,5 ms)

`ILIKE '%texto%'` **no es SARGable**: ningún B-tree puede resolver una subcadena con comodín inicial. Control ejecutado con `enable_indexscan=off`: 5.074 ms (seq scan de 6M).

Solución: `pg_trgm` + índice GIN. Plan nuevo: `Bitmap Index Scan on Article_title_trgm_idx`, **0,55 ms de ejecución**.

4. Índices y objetos creados: justificación y costo

Objeto	Consulta que sirve	Tamaño	Costo de creación medido
`mv_tag_counts` (+2 índices)	Q4	480 kB + 184 kB	0,64 s
`mv_article_favorites` (+2 índices)	Q7	422 MB + 169 MB	5,8 s + 8,2 s

Objeto	Consulta que sirve	Tamaño	Costo de creación medido
`Article_title_trgm_idx` (GIN)	Q8	198 MB	**28,8 s**

Impacto total: la base pasó de 7.874 MB a **8.551 MB (+677 MB, +8,6 %)**.

Ese número es el argumento central contra "crear índices por las dudas": cada índice se paga en disco y en tiempo de escritura. La vista de favoritos es la más cara (591 MB con índices) y se justifica solo porque el top de favoritos se muestra en la home.

Optimización descartada (control negativo)

Se probó un índice parcial en `User(demo)`:

Escenario	count sin tope
con `User_demo_partial_idx`	478 ms
sin el índice	568 ms

Diferencia dentro del ruido, y el filtro **no es selectivo** (200.000 de 200.000 usuarios tienen `demo = true`). Se **eliminó el índice** y se documenta el intento: un índice que no mejora nada es deuda.

5. Parámetros del motor

Parámetro	Valor	Motivo
`shared_buffers`	1 GB	base de 8,5 GB: ~12 %, dentro de lo recomendado
`effective_cache_size`	3 GB	estimación para el planificador
`work_mem`	16 MB	los `GROUP BY` grandes se materializaron, ya no necesitan más
`max_wal_size`	8 GB	la carga masiva generaba 38 GB de WAL con el default (D-20)
`checkpoint_timeout`	15 min	ídem
`log_min_duration_statement`	200 ms	alimenta pgBadger (§4)

6. Limitaciones

- **El conteo acotado cambia semántica**: `articlesCount` tope 10.000 (1.000 páginas de 10). Es una decisión de producto, no un techo técnico; se documenta para que no sorprenda.
- Las vistas materializadas tienen **atraso** hasta el próximo refresco. Se refrescan por cron (n8n) y se documenta el intervalo.
- Las optimizaciones de Q2b, Q4 y Q7 están implementadas en SQL; la API todavía usa `OFFSET` y consultas directas. La integración de keyset pagination y de las vistas en el backend queda como mejora pendiente (no afecta la demo: el listado ya bajó a 0,19 s por el cambio de Q1).
- Las mediciones son con caché caliente; en frío los números son peores para todas las variantes.

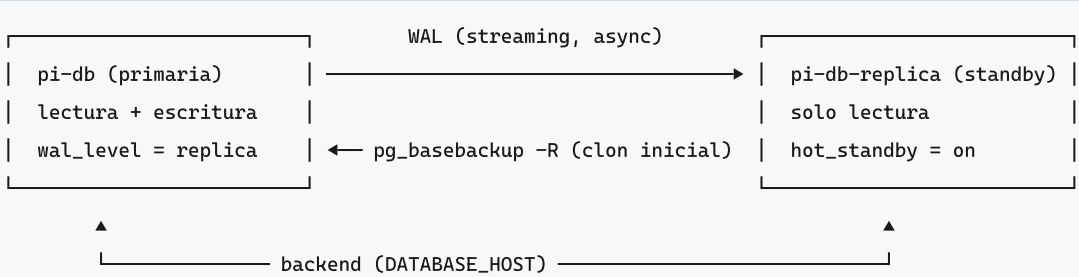
7. Evidencia

Evidencia	Archivo
Baseline (8 consultas + planes)	`evidence/05/baseline-1.txt`
Después (optimizaciones + planes)	`evidence/05/optimizado.txt`
Control negativo (índice descartado, Q8 sin índice)	`evidence/05/control.txt`
Consultas usadas	`db/queries/10-baseline.sql` , `db/queries/20-optimizado.sql`
Consultas más costosas del motor	`pg_stat_statements` (top 8 por tiempo total)

08 — Configuración y pruebas de replicación

1. Arquitectura implementada

Primaria + 1 réplica en streaming asíncrona, sin failover automático.



Nodo	Rol	Puerto publicado	Persistencia
`pi-db`	primaria: recibe todas las escrituras	`127.0.0.1:5433`	volumen `pi-pgdata`
`pi-db-replica`	standby: replay continuo, solo lectura	**ninguno**	volumen `pi-pgdata-replica`

2. Configuración

Primaria (`compose.yaml`, servicio `db`)

Parámetro	Valor	Motivo
`wal_level`	`replica`	necesario para enviar WAL con información suficiente para consultas en standby
`max_wal_senders`	`10`	conexiones de envío concurrentes
rol `replicador`	`REPLICATION LOGIN` con contraseña desde `.env`	credencial específica, no la de la aplicación
`pg_hba.conf`	`host replication replicador 172.16.0.0/12 scram-sha-256`	solo la red interna de Docker puede replicar

El rol y la regla de `pg_hba` se crean con `db/init/05-replicacion.sh` (idempotente: se puede volver a ejecutar sin duplicar nada).

Réplica (`db/replica/entrypoint.sh`)

1. Si el volumen está vacío: `pg_basebackup -h db -U replicador -D $PGDATA -Fp -Xs -R -P`. El `-R` escribe `primary_conninfo` y crea `standby.signal`: eso es todo lo que convierte al nodo en standby.
2. Si ya hay datos: arranca directamente (un reinicio no vuelve a clonar).

3. Verificación de replicación

Comprobación	Resultado
`pg_stat_replication` en la primaria	`state = streaming`, `sync_state = async`, **lag = 0 bytes**
`pg_is_in_recovery()` en la primaria	`false` (es primaria)
Réplicas conectadas	1
`pg_is_in_recovery()` en la réplica	`true` (es standby)
Escritura en primaria visible en réplica	**447 ms** (incluye el sondeo cada 200 ms)
Escritura directa en la réplica	rechazada: `cannot execute INSERT in a read-only transaction`

Evidencia: `evidence/06/replicacion.log`.

4. Pruebas de fallo

Escenario	Resultado medido
A) Se detiene la réplica	la app sigue respondiendo **200 en 0,198 s**; sin impacto porque escribe en la primaria
B) Se detiene la primaria	primera respuesta no-200 a los **1,4 s**; 20/20 fallos en 10 s (HTTP 500)
C) Failover manual (`pg_promote`)	promoción en **1,2 s**; nodo fuera de recovery
C2) Repunte de la app	`DATABASE_HOST=db-replica` + recrear el backend
C3) RTO total	**8,6 s** desde el inicio de la promoción hasta que la app vuelve a responder 200
C4) Escritura en el nodo promovido	`POST /api/users` → **201**; 200.002 usuarios

Evidencia: `evidence/06/failover.log`.

5. Failover: procedimiento manual (no automático)

```
# 1. detectar que la primaria no responde (monitoreo o healthcheck)
docker compose stop db

# 2. promover la réplica
./scripts/replica.ps1 promote        # pg_promote()

# 3. repuntar la aplicación
#    .env -> DATABASE_HOST=db-replica
docker compose up -d --force-recreate backend

# 4. verificar
curl http://127.0.0.1:8090/api/articles?limit=3
```

No hay detección automática de falla ni promoción automática. No se usa Patroni/repmgr: el enunciado advierte que la replicación por sí sola no garantiza alta disponibilidad, y afirma que si se declara failover automático hay que demostrarlo. Acá se declara **failover manual**, con el procedimiento ejecutado y el RTO medido.

6. Divergencia detectada (lo más importante de la prueba)

Al promover la réplica y seguir escribiendo, el nodo promovido quedó con **un usuario que la primaria vieja no tiene** (`failover_demo`). Al restaurar la topología original hubo que **descartar el volumen de la réplica promovida y volver a clonar**, perdiendo esa escritura.

Eso no es un defecto del procedimiento: es la naturaleza de un failover manual sin cuórum. Si la primaria "caída" en realidad solo estaba aislada (split-brain), ambas aceptarían escrituras y habría que reconciliar. Un sistema con promoción automática necesita un mecanismo de cuórum (Patroni + etcd) para evitar exactamente esto.

Consecuencia documentada: RPO ≠ 0. En replicación asíncrona se puede perder el WAL que no llegó a la réplica. En la prueba el lag era 0 bytes, así que la pérdida fue de la escritura hecha *después* de la promoción, no antes.

7. Limitaciones

Limitación	Impacto	Mejora posible
Sin failover automático	RTO depende de una persona (~9 s medidos, más el tiempo de detección)	Patroni + etcd o repmgr

Limitación	Impacto	Mejora posible
Replicación asíncrona	RPO > 0 ante caída abrupta	`synchronous_commit=remote_apply` (más latencia)
La app necesita repunte manual	un `DATABASE_HOST` y un reinicio	proxy (HAProxy/pgBouncer) o driver con failover
Sin balanceo de lecturas	la réplica no se usa para consultas	`read replica` de Prisma no existe en 4.x; requiere segundo cliente o proxy
Un solo standby	sin cuórum ni segunda copia	añadir una segunda réplica

8. Evidencia

Evidencia	Archivo
Estado, lag, escritura→lectura, solo-lectura	`evidence/06/replicacion.log`
Pruebas de fallo, promoción y RTO	`evidence/06/failover.log`
Configuración	`compose.yaml`, `db/replica/entrypoint.sh`, `db/init/05-replicacion.sh`
Script de operación	`scripts/replica.ps1`
Consultas de verificación	`db/queries/30-replicacion.sql`

09 — Integración y despliegue continuos

1. Objetivo

Que ninguna modificación defectuosa llegue a `main` ni al entorno publicado, que el despliegue sea reproducible, y que si una versión nueva rompe el servicio el sistema vuelva solo a la anterior.

2. Herramienta

GitHub Actions, porque el repositorio ya vive en GitHub: no hace falta infraestructura extra ni credenciales adicionales, y los *status checks* se integran nativamente con la protección de rama.

3. Integración continua (`.github/workflows/ci.yml`)

Se dispara en `push` y `pull_request` sobre `main` y `develop`.

Job	Qué hace	Por qué
`backend`	`npm ci` + `npm run build` (Nx, Node 20)	el backend debe compilar antes de construir la imagen
`frontend`	`npm ci` + `eslint` + `vite build` + artefacto `frontend-dist`	lint y build son la barrera mínima de calidad
`secrets`	`gitleaks` sobre **todo el historial** con `--redact`	un secreto puede estar en un commit viejo, no solo en el HEAD
`compose`	`docker compose config` + control de que `.env` no está versionado	un compose inválido rompe el despliegue; un `.env` versionado filtra credenciales

Decisiones de diseño:

- **`npm ci` , no `npm install`** : exige lockfile y garantiza que el build de CI sea el mismo que el local.
- **Node 20 fijo**: el host tiene Node 26, pero CI y Docker usan la misma versión LTS.
- **`permissions: contents: read`** : el workflow de CI no necesita escribir nada.
- **`concurrency` con `cancel-in-progress`** : dos pushes seguidos no encolan dos pipelines completos.
- **`gitleaks` por imagen Docker**: no requiere token ni licencia de la action.

4. Protección de `main`

Configurada por API (`evidence/03/branch-protection.json`):

Regla	Valor	Efecto
Pull request obligatorio	sí	no se puede pushear directo
Status checks requeridos	`backend` , `frontend` , `secrets` , `compose`	el merge se bloquea si algún job falla
`strict`	sí	la rama debe estar actualizada con `main` antes de mergear
`enforce_admins`	**sí**	la regla también aplica al dueño del repositorio
Force push	no	no se puede reescribir el historial
Borrado de la rama	no	—

Prueba negativa ejecutada (`evidence/03/branch-protection-test.log`):

```
remote: error: GH006: Protected branch update failed for refs/heads/main.
remote: - Changes must be made through a pull request.
remote: - 4 of 4 required status checks are expected.
 ! [remote rejected] main -> main (protected branch hook declined)
```

Ese intento se hizo **con la cuenta dueña del repositorio** y aun así fue rechazado: es la prueba de que `enforce_admins=true` está funcionando y no es una regla decorativa.

> Anécdota que vale para la defensa: la primera configuración tenía `enforce_admins=false` y el push directo **pasó**. GitHub lo informó como "*Bypassed rule violations*". Se detectó justamente porque se probó el caso negativo en lugar de asumir que la configuración estaba bien.

5. Publicación de imágenes (`.github/workflows/release.yml`)

Se dispara **solo con push a** `main` (y `workflow_dispatch`). No corre en PRs: publicar imágenes de código que todavía no se mergeó llena el registro de versiones que nadie va a desplegar.

Aspecto	Decisión
Registro	**GHCR** (`ghcr.io/tomasgudi/hia-2026-{backend,frontend}`)
Tags	`sha-<7>` (trazable al commit) + `latest`
Matriz	un job por servicio, en paralelo
Caché	`type=gha` por servicio: no recompila capas entre corridas
Permisos	`contents: read` + `packages: write` (el único permiso de escritura)
Labels	`org.opencontainers.image.{source,revision,version}` vía `metadata-action`

El tag `sha-<7>` es el que se usa para desplegar: `latest` es una comodidad, no una referencia estable. Desplegar `latest` en producción es un error clásico porque no se sabe qué código corre.

6. Registro

CI publica en **GHCR** y el despliegue baja de ahí. Verificado: el paquete quedó público (repositorio público) y se puede bajar sin credenciales:

```
docker pull ghcr.io/tomasgudi/hia-2026-backend:sha-0946375
Digest: sha256:7c81e91823a992a85bc60660420b213c7d438918663a2f724e56ab1346964bc8
Status: Downloaded newer image for ghcr.io/tomasgudi/hia-2026-backend:sha-0946375
```

```
./scripts/deploy.ps1 -Tag sha-0946375 -Registry ghcr.io/tomasgudi
```

Además hay un **registro local** (`registry:2` en `127.0.0.1:5000` , perfil `ops`) con las mismas imágenes. No es el camino principal: es el plan B para un host sin salida a Internet o si el paquete se vuelve privado. En ese caso `deploy.ps1` funciona igual cambiando `-Registry` .

Si el paquete fuera privado, el host necesitaría `docker login ghcr.io` con un PAT que tenga `read:packages` . Este entorno no lo tenía, y por eso se probó primero el registro local; después se confirmó que el paquete de GHCR era accesible y se desplegó desde ahí.

7. Despliegue pull-based (`scripts/deploy.ps1`)

No hay *push* desde GitHub al host: el host **baja** la versión que se le indica. Es el patrón correcto cuando el destino no tiene una IP pública ni un runner self-hosted.

```
./scripts/deploy.ps1 -Tag sha-1a2b3c4     # despliegue normal
./scripts/deploy.ps1 -Rollback            # volver a la versión anterior
```

Secuencia:

1. **Baja las dos imágenes antes de tocar nada.** Si el pull falla, el servicio actual sigue corriendo: el despliegue aborta sin dejar el sistema a medias.
2. Escribe el tag en `BACKEND_IMAGE`, `FRONTEND_IMAGE` y `APP_VERSION`.
3. `docker compose up -d --no-build --no-deps backend frontend` (solo esos dos servicios).
4. Espera salud **real**: `GET /health` a través del frontend **y** `docker inspect` en `healthy`.
5. Si no queda sano en el timeout, **rollback automático** al tag anterior y vuelve a verificar.

El estado queda en `.deploy/state.json` (no versionado): `current`, `previous`, `history`, `failed_tag` si hubo rollback.

`GET /health` devuelve la versión desplegada:

```
{"status":"ok","db":"up","uptime":31.06,"version":"v1"}
```

Eso permite responder "¿qué está corriendo?" sin entrar al contenedor.

8. Rollback probado

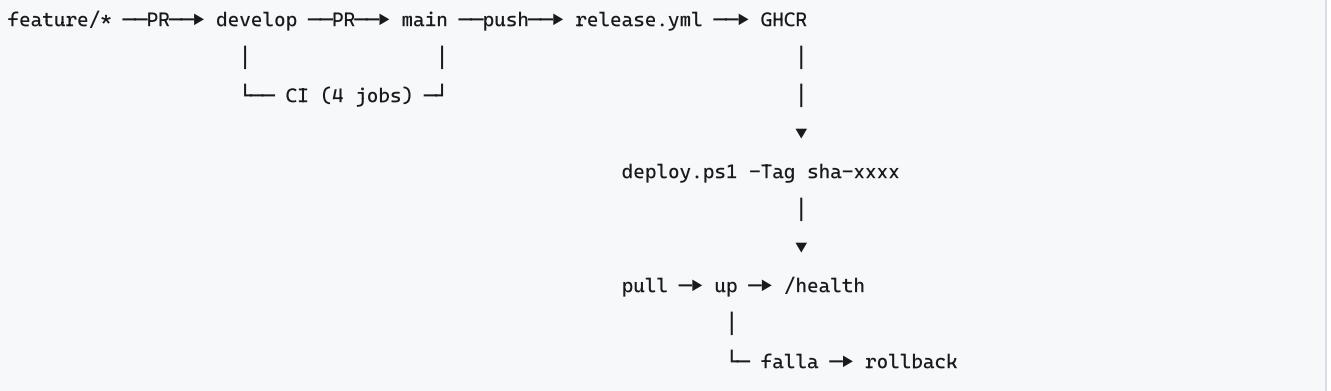
Paso	Acción	Resultado
1	`deploy.ps1 -Tag v1`	`version: v1`, app 200
2	`deploy.ps1 -Tag v2`	`version: v2`, app 200
3	`deploy.ps1 -Tag broken`	el contenedor no levanta: `dependency failed to start`
4	rollback **automático**	vuelve a `v2` sin intervención; `version: v2`, app 200
5	`deploy.ps1 -Rollback`	vuelve a `v1`; `version: v1`, app 200
6	`deploy.ps1 -Tag sha-0946375 -Registry ghcr.io/tomasgudi`	imagen de GHCR desplegada; `version: sha-0946375`

La imagen `broken` es un `alpine` que no escucha en `:3000`: no es un error simulado en el script, es un contenedor que realmente no sirve. El rollback se dispara porque el healthcheck falla, no porque el script "sepa" que esa imagen es mala.

Evidencia: `evidence/08/deploy.log`, `evidence/08/rollback-automatico.log`, `evidence/08/rollback-manual.log`, `evidence/08/registro-y-despliegue.log`.

> Nota honesta: `v1` y `v2` son el **mismo commit con distinto tag**. Lo que se prueba es el mecanismo de despliegue y rollback, no un cambio de código. En un release real el tag `sha-<7>` cambia con el commit.

9. Flujo completo



10. Estado

Requisito de §8	Estado
Configurar GitHub Actions	✅
Verificaciones automáticas	✅ lint, build, secretos, compose
Construir imágenes Docker	✅ `release.yml`, matriz backend/frontend
Publicar en un registro	✅ GHCR + registro local para el host
Despliegue automático	✅ pull-based con `deploy.ps1`
Secretos protegidos	✅ `GITHUB_TOKEN` con permisos mínimos; gitleaks en todo el historial
Commit de prueba	✅ PRs #1–#5 con CI verde
Rollback documentado y probado	✅ automático y manual, con evidencia

11. Evidencia

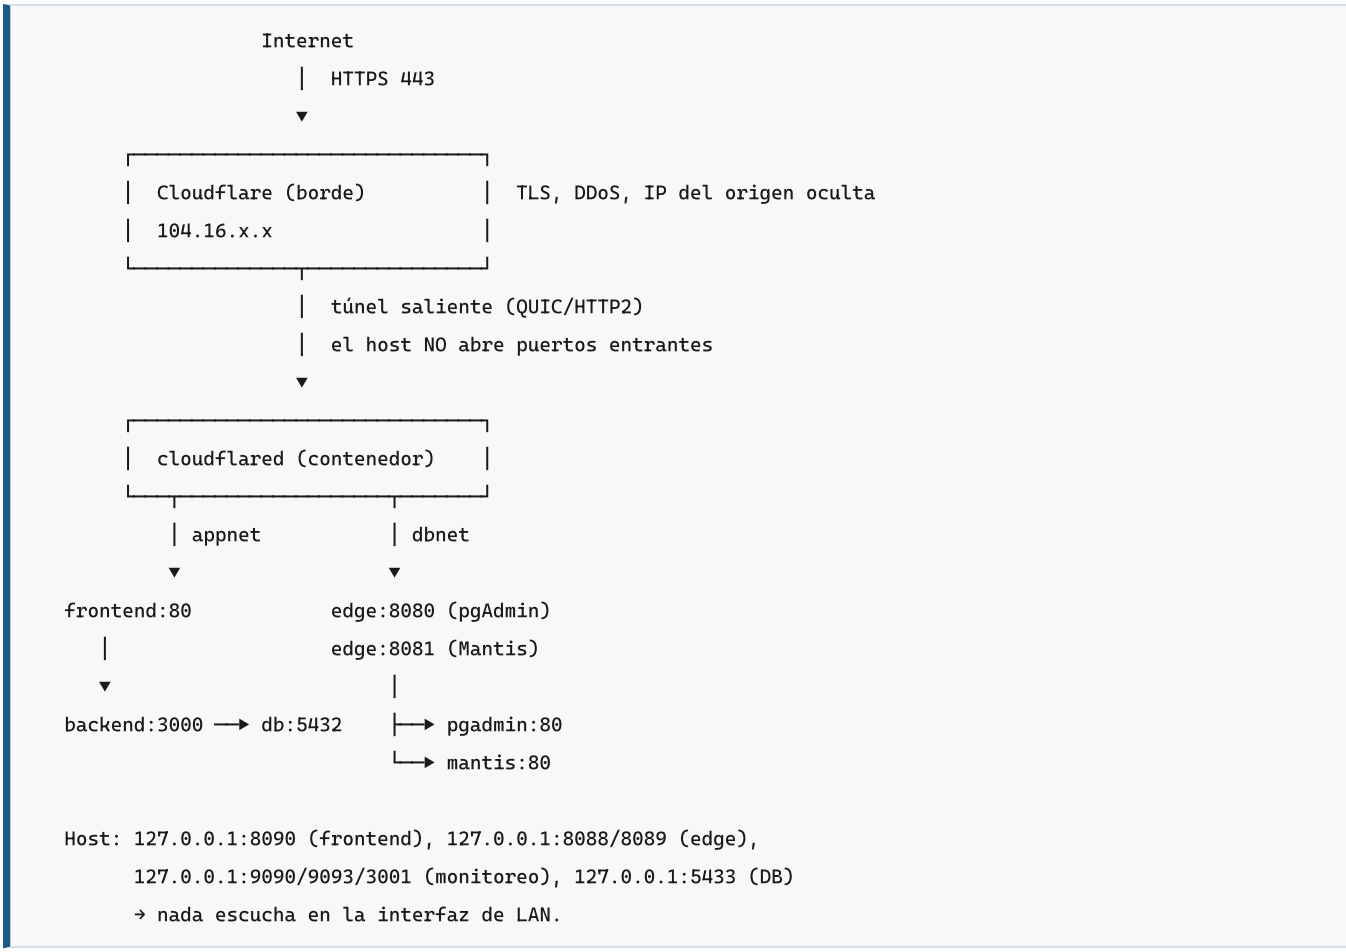
Evidencia	Archivo
Workflow de CI	`.github/workflows/ci.yml`
Workflow de release	`.github/workflows/release.yml`
Corrida exitosa de CI (4/4 jobs)	`evidence/03/ci-evidencia.txt`, `evidence/03/ci-run-43424320086.json`
Configuración de protección	`evidence/03/branch-protection.json`
Prueba negativa de protección	`evidence/03/branch-protection-test.log`
Escaneo de secretos	`evidence/03/gitleaks.log`
Despliegue v1 → v2	`evidence/08/deploy.log`
Rollback automático	`evidence/08/rollback-automatico.log`
Rollback manual	`evidence/08/rollback-manual.log`
Registro y digests (local)	`evidence/08/registro-y-despliegue.log`
Publicación en GHCR	`evidence/08/ghcr-release.log`
Despliegue desde GHCR por SHA	`evidence/08/deploy-desde-ghcr.log`
Prueba negativa de CI	`evidence/03/ci-negativo.log`, `evidence/03/ci-negativo-job.log`, `evidence/03/ci-negativo-checkruns.json`
Script de despliegue	`scripts/deploy.ps1`

10 — Publicación en Internet

1. Objetivo

Que la aplicación sea accesible desde Internet **sin abrir un solo puerto** en el host, con HTTPS, y que las herramientas de administración queden detrás de autenticación. Además, demostrar con `nmap` que la superficie expuesta es la mínima.

2. Arquitectura de publicación



La clave: **el túnel es una conexión saliente**. `cloudflared` inicia la conexión hacia Cloudflare y mantiene un canal abierto; Cloudflare le reenvía el tráfico. No hay NAT, ni port forwarding, ni IP pública, ni certificado que renovar en el origen.

3. Endpoints publicados

Servicio	URL pública (túnel rápido)	Auth
Aplicación	`https://macintosh-pension-california-grey.trycloudflare.com`	login propio de la app (JWT)
pgAdmin	`https://progress-bulk-trailers-traditions.trycloudflare.com`	**Basic auth** + login de pgAdmin
Mantis	`https://experts-baseball-simulation-floating.trycloudflare.com`	**Basic auth** + login de Mantis

Comando usado (túnel rápido, sin cuenta):

```
docker run -d --name pi-tunnel --network pi-appnet cloudflare/cloudflared:latest \
  tunnel --no-autoupdate --url http://frontend:80
```

> **Estas URLs son efímeras**: los túneles rápidos mueren al detener el contenedor y el nombre cambia. Para la defensa hay que levantarlos de nuevo y usar la URL que imprima el log. En producción se usa un **túnel con nombre** y un dominio propio (ver §7).

4. Autenticación en rutas administrativas

`edge/nginx.conf` publica pgAdmin y Mantis detrás de HTTP Basic:

```
auth_basic           "Administracion - Practica Integradora";
auth_basic_user_file /etc/nginx/.htpasswd;
```

- El hash es **apr1** (`$apr1$...`), no la contraseña: `edge/.htpasswd` se puede versionar.
- La contraseña vive en `.env` (`EDGE_ADMIN_PASSWORD`) y no se versiona.
- Basic auth **no reemplaza** el login propio de cada herramienta: lo antepone. Dos barreras.

Verificación sobre HTTPS público:

Petición	Resultado
`GET pgadmin/` sin credenciales	**401**
`GET mantis/` sin credenciales	**401**
`GET pgadmin/` con clave incorrecta	**401**
`GET pgadmin/` con credenciales	**308** → login de pgAdmin
`GET mantis/` con credenciales	**302** → login de Mantis

5. Verificación de superficie con `nmap`

5.1 Desde la LAN (¿el host expone algo?)

```
docker run --rm instrumentisto/nmap -Pn -T4 -p 5000,3001,5433,8080,8081,8088,8089,8090,9090,9093 192.168.1.8
```

```
PORT     STATE    SERVICE
3001/tcp filtered nessus
5000/tcp filtered upnp
5433/tcp filtered pyrrho
8080/tcp filtered http-proxy
8081/tcp filtered blackice-icecap
8088/tcp filtered radan-http
8089/tcp filtered unknown
8090/tcp filtered opsmessaging
9090/tcp filtered zeus-admin
9093/tcp filtered copycat
```

Todos `filtered`. No es casualidad: cada puerto del compose está publicado como `127.0.0.1:<puerto>`, así que Docker los ata al loopback y no a la interfaz de red.

5.2 Desde Internet (¿qué se ve del otro lado?)

```
docker run --rm instrumentisto/nmap -Pn -p 80,443 macintosh-pension-california-grey.trycloudflare.com
```

```
Nmap scan report for ...trycloudflare.com (104.16.231.132)
PORT    STATE SERVICE
80/tcp  open  http
443/tcp open  https
```

Lo que se ve es **Cloudflare**, no el host. El origen no tiene dirección pública: no hay nada que escanear del otro lado. Ese es el punto del túnel.

6. Riesgos y limitaciones

Riesgo	Impacto	Mitigación / decisión
Túnel rápido sin SLA	la URL muere y no hay garantía de uptime	es para demo; producción usa túnel con nombre
Basic auth sin MFA	una contraseña filtrada da acceso al panel	contraseña fuerte en `.env` + login propio de la herramienta; Cloudflare Access para MFA
pgAdmin expuesto a Internet	superficie de ataque alta si hay un CVE	se publica solo con auth; en producción conviene VPN o Access
Cloudflare ve el tráfico	el TLS termina en el borde	aceptable para esta práctica; alternativa: túnel con TLS de extremo a extremo
Sin rate limiting ni WAF	fuerza bruta / abuso	reglas de Cloudflare (no configuradas, requieren cuenta)
Un solo nodo	si el host cae, el túnel cae	no hay alta disponibilidad; es una limitación del alcance
Sin logs de acceso centralizados	difícil auditar intentos	se mitiga con §10 (métricas) y logs de `cloudflared`

Lo que NO se hizo y por qué: no se configuró Cloudflare Access (requiere cuenta y dominio), no se configuró WAF ni rate limiting, y no se usó un túnel con nombre. Todo eso es la evolución natural de esta arquitectura, no una omisión silenciosa.

7. Plan B: Tailscale Funnel

Se evaluó como alternativa. **No se implementó**: requiere cuenta de Tailscale y un `tailscale up` interactivo, igual que un túnel con nombre de Cloudflare requiere dominio propio.

Procedimiento si se quisiera:

```
tailscale up --advertise-exit-node=false
tailscale funnel 8090
```

Diferencia con Cloudflare: Funnel publica el servicio en `*.ts.net` sin abrir puertos, pero el tráfico entra por la red de Tailscale (WireGuard) y no hay borde con DDoS/WAF. Para esta práctica Cloudflare es mejor opción porque además aporta TLS y ocultamiento del origen.

8. Evidencia

Evidencia	Archivo
Acceso externo (HTTPS, auth, versión desplegada)	`evidence/09/acceso-externo.log`
`nmap` desde la LAN y contra el endpoint público	`evidence/09/nmap.log`
Configuración del borde	`edge/nginx.conf` , `edge/.htpasswd`
Servicios en `compose.yaml`	`edge` , túneles creados con `docker run`

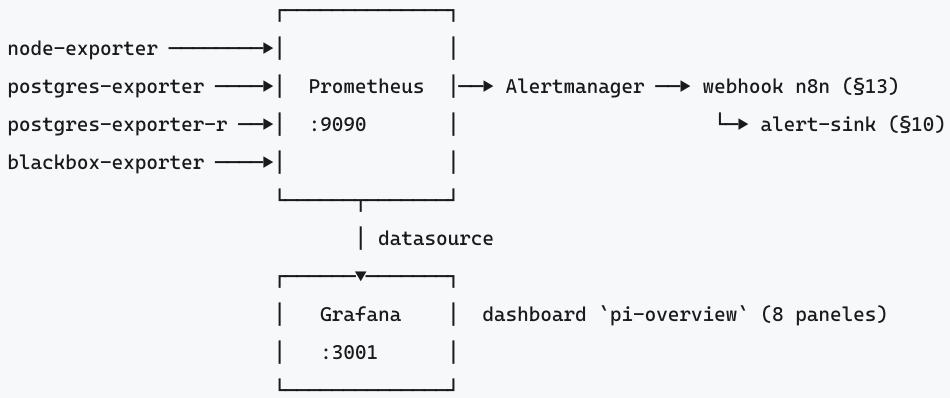
11 — Monitoreo

1. Objetivo y alcance

Saber **qué está pasando** antes de que lo reporte un usuario, y tener evidencia de que la alerta llega a una persona (o a un sistema) con el contexto suficiente para actuar.

Alcance de esta sección: métricas de infraestructura, del motor de base de datos, de la replicación y de la disponibilidad HTTP real. Queda fuera el APM a nivel de código (traces) y la observabilidad de logs centralizada: se documentan como limitación en §7.

2. Arquitectura



Componente	Imagen	Puerto publicado	Para qué
Prometheus	`prom/prometheus:v2.54.1`	`127.0.0.1:9090`	recolección (15 s) y evaluación de reglas
Alertmanager	`prom/alertmanager:v0.27.0`	`127.0.0.1:9093`	agrupación, silencios y envío de notificaciones
Grafana	`grafana/grafana:11.2.0`	`127.0.0.1:3001`	dashboard provisionado por archivo
node-exporter	`prom/node-exporter:v1.8.2`	—	CPU, memoria, disco, red del anfitrión
postgres-exporter	`prometheuscommunity/postgres-exporter:v0.15.0`	—	métricas del motor: primaria
postgres-exporter-replica	ídem	—	métricas del motor: standby
blackbox-exporter	`prom/blackbox-exporter:v0.25.0`	—	sondeo HTTP real de los servicios
alert-sink	`python:3.12-alpine`	—	receptor de evidencia del webhook

Todo el monitoreo corre bajo el perfil `ops`:

```
docker compose --profile ops up -d
```

Ningún puerto sale de loopback. El acceso remoto va por el túnel de §9.

3. Targets y qué mide cada uno

Job	Target	Métricas que aporta
`prometheus`	`localhost:9090`	salud del propio Prometheus (sirve para detectar evaluación atrasada)
`node`	`node-exporter:9100`	`node_cpu_seconds_total`, `node_memory_*`, `node_filesystem_*`, `node_load*`, `node_network_*`
`postgres`	`postgres-exporter:9187`	`pg_up`, conexiones, cache hit, `pg_stat_replication_pg_wal_lsn_diff`
`postgres-replica`	`postgres-exporter-replica:9187`	`pg_replication_lag_seconds`, `pg_replication_is_replica`
`blackbox`	`http://frontend/`, `http://backend:3000/health`, `http://mantis/`	`probe_success`, `probe_duration_seconds`

Por qué blackbox y no solo `up`: `up` dice que el exporter respondió; no dice que el servicio detrás responda. `probe_success` hace una petición HTTP real y verifica el código 2xx.

Por qué un usuario `monitor` y no el de la aplicación: `postgres_exporter` solo necesita leer vistas de estadísticas. Se crea con `db/init/06-monitoreo.sh` y se le otorga el rol predefinido `pg_monitor` (agrupa `pg_read_all_stats` y `pg_read_all_settings`), sin acceso a los datos.

4. Las 6 reglas y su umbral

#	Alerta	Expresión	for	Severidad	Por qué ese umbral
R1	`ServicioCaido`	`(up{job!="prometheus"} == 0) or (probe_success == 0)`	2m	critical	2m descarta reinicios normales de contenedor; cubre caída del exporter y del servicio
R2	`CPUAlta`	CPU del anfitrión > 85%	5m	warning	85% deja 15% de margen antes de saturar; 5m descarta picos de build. Verificado: `stress-ng` con 16 workers sobre 8 vCPU lleva la CPU a 100%
R3	`MemoriaAlta`	memoria usada > 90%	5m	warning	deja margen antes de que el OOM killer mate un contenedor
R4	`DiscoCasiLleno`	disco raíz usado > 85%	5m	warning	un disco lleno rompe PostgreSQL (no puede escribir WAL); 15% libre da tiempo a purgar
R5	`PostgresCaido`	`pg_up == 0`	1m	critical	sin base la app no sirve nada: es la única con 1m
R6	`ReplicacionAtrasada`	`max(pg_stat_replication_pg_wal_lsn_diff) > 100 MB` **o** `absent(...)`	2m	critical	100 MB es un RPO que conviene mirar; `absent()` cubre el caso peor: ninguna réplica conectada

Criterio transversal: **una alerta que no es accionable es ruido**. Cada regla tiene en su anotación `description` la acción concreta a ejecutar, no solo el síntoma.

Las alertas de recursos se agrupan (`group_by: [alertname, severity]`) para que una saturación no genere una notificación por cada serie.

5. Dashboard (`monitoring/dashboards/pi-overview.json`)

Versionado como JSON y provisionado por archivo (`updateIntervalSeconds: 30`): no se edita a mano en la UI. 8 paneles:

#	Panel	Fuente	Para qué
1	CPU del anfitrión	node-exporter	detectar saturación
2	Memoria del anfitrión	node-exporter	riesgo de OOM
3	Disco raíz	node-exporter	riesgo de no poder escribir WAL
4	Carga del sistema y procesos	node-exporter	distinguir CPU alta por carga real de un pico puntual
5	Red del anfitrión	node-exporter	ver el corte de tráfico en un failover
6	Disponibilidad y latencia HTTP	blackbox-exporter	¿el servicio responde y cuánto tarda?
7	PostgreSQL: conexiones y cache hit	postgres-exporter	saturación de conexiones y eficiencia de memoria
8	Replicación: lag de WAL	ambos exporters	estado de replicación (§6)

El panel 8 usa **dos perspectivas**: `pg_stat_replication_pg_wal_lsn_diff` (bytes que le faltan al standby, medido desde la primaria) y `pg_replication_lag_seconds` (segundos desde el último replay, medido desde la réplica). Un panel que solo mirara uno de los dos lados no distinguiría "la réplica no recibe WAL" de "la réplica recibe pero no aplica".

Acceso: `http://127.0.0.1:3001/d/pi-overview`. Lectura anónima habilitada **solo en loopback** para la demo; el usuario `admin` conserva su contraseña.

5.1 Prueba de anomalía (cadena completa)

Objetivo: verificar que una anomalía real recorre **métrica** → **regla** → **Alertmanager** → **webhook**, no solo que la regla existe.

```
./scripts/monitoreo.ps1 test-alerta -Minutos 13
```

El script lanza `stress-ng` en un contenedor efímero (16 workers, **sin** límite de `--cpus`) y sigue el estado de la regla leyéndolo de la API de reglas de Prometheus.

Momento	CPU	Estado de `CPUAlta`
t = 1 s	3,4%	`inactive`
t = 262 s	99,9%	`pending`
t = 564 s	99,9%	**`firing`**
t = 585 s	—	fin de la prueba; se retira el contenedor

Alertmanager recibió la notificación 10 s después (`group_wait: 10s`):

```
{"status": "firing",
 "alerts": [{"labels": {"alertname": "CPUAlta", "severity": "warning"},
             "annotations": {"summary": "CPU del anfitrión al 100.0%",
                             "description": "CPU sostenida por encima del 85% durante 5 minutos..."}}]}
```

Al retirar el estrés la expresión vuelve a `false`, la alerta se resuelve y Alertmanager envía el `resolved` (`send_resolved: true`).

Por qué 13 minutos y no 2: la regla usa `rate(...[5m])` y `for: 5m`. La ventana de 5m tarda unos 5 minutos en reflejar la carga real, y después hay que sostenerla 5 minutos más. Una prueba más corta no verifica la regla: verifica que no dispara. La primera corrida (8 min) fue exactamente ese error.

Lección registrada: la primera medición se hizo con `docker run --cpus 6`, que topa el contenedor en 6 de 8 vCPU (75%). La CPU se estabilizó en 77,7% y la alerta nunca disparó. Al medir capacidad con un generador de carga limitado se mide el límite del cgroup, no la del anfitrión.

6. Limitaciones encontradas (y qué se hizo)

cAdvisor no funciona en Docker Desktop

Se intentó `gcr.io/cadvisor/cadvisor:v0.49.1` para métricas por contenedor. Falla al enumerar:

```
Failed to create existing container: /docker/<id>:
failed to identify the read-write layer ID ...
open /rootfs/var/lib/docker/image/overlayfs/layerdb/mounts/<id>/mount-id: no such file or directory
```

Causa: Docker Desktop usa el **snapshotter de containerd**, así que `/var/lib/docker/image/overlayfs` no existe. Se probó también con `--containerd=/run/containerd/containerd.sock --containerd-namespace=moby`: el factory de containerd registra correctamente, pero no enumera los contenedores de Docker Desktop y cAdvisor cae al handler `raw` (series sin label `name`).

Decisión: se retira cAdvisor y los paneles 4 y 5 pasan a carga del sistema y red del anfitrión. El estado de cada servicio se cubre con `up` y con los sondeos HTTP del panel 6. Se documenta en vez de dejar un panel vacío o un contenedor privilegiado que no aporta datos.

Las métricas de "anfitrión" son las de la VM de Linux

`node-exporter` corre dentro de la VM de Docker Desktop, no en Windows. Mide los 8 vCPU y la memoria asignados a esa VM. Es correcto para lo que corre en contenedores, pero **no** es el consumo de Windows. En un servidor Linux real la distinción desaparece.

Nota de medición: la primera prueba con `docker run --cpus 6` se estabilizó en **77,7%** — el límite de cgroup era exactamente 6 de 8 vCPU (75%) más la carga del stack. Con `--cpus 8` el contenedor seguía limitado por la cuota y la lectura no subía. La prueba correcta es **sin** `--cpus` y con sobre-suscripción (`stress-ng --cpu 16`): ahí la CPU llega a **100%** y la regla de 85% dispara. Lección registrada: al medir con un límite de cgroup se está midiendo el límite, no la capacidad del anfitrión.

Un solo nodo de monitoreo

Prometheus, Alertmanager y Grafana corren en el mismo host que lo monitoreado. Si el host cae, no hay alerta (no hay quien la emita). La solución real es un Prometheus externo con `remote_write`, o un segundo nodo con Thanos/Mimir. Se declara como limitación, no se simula.

7. Fuera de alcance

No implementado	Por qué	Mejora posible
Logs centralizados	el alcance es métricas; los logs se leen con `docker compose logs`	Loki + Promtail
Trazas (APM)	requiere instrumentar el backend	OpenTelemetry
Retención larga	15 días en el volumen local	`remote_write` a Mimir/Thanos
Monitoreo del propio monitoreo	un nodo solo no puede alertar de su propia caída	segundo nodo + watchdog externo

8. Operación

```
./scripts/monitoreo.ps1 status        # targets, reglas y alertas activas
./scripts/monitoreo.ps1 urls          # URLs de los tres servicios
./scripts/monitoreo.ps1 test-alerta   # prueba de anomalía con stress-ng
./scripts/monitoreo.ps1 recargar      # recarga la configuración de Prometheus
```

9. Evidencia

Evidencia	Archivo
Estado de targets, reglas y alertas	`evidence/10/monitoreo-estado.log`
Prueba de anomalía con `stress-ng`	`evidence/10/alerta-stress.log`
Payload recibido por el webhook	`evidence/10/alertmanager-payloads.jsonl`
Dashboard versionado	`monitoring/dashboards/pi-overview.json`
Reglas	`monitoring/prometheus/rules.yml`
Configuración de scrape	`monitoring/prometheus/prometheus.yml`
Ruteo de alertas	`monitoring/alertmanager/alertmanager.yml`

12 — Gestión de incidencias (Mantis)

1. Objetivo

Registrar, priorizar y resolver los defectos detectados durante el desarrollo y las pruebas, con trazabilidad hacia el código (§11).

2. Herramienta y despliegue

Aspecto	Decisión	Motivo
Herramienta	**MantisBT 2.28.4**	el enunciado la nombra explícitamente en §11 y en §13 (flujo 1)
Imagen	**propia** (`app/mantis/Dockerfile`)	no existe imagen oficial en Docker Hub; las comunitarias no fijan versión ni tienen mantenimiento verificable (riesgo de cadena de suministro, §14)
Fuente	paquete oficial de SourceForge	el tarball de GitHub **no incluye** `vendor/` y el instalador falla con `Failed opening required vendor/autoload.php`
Base de datos	PostgreSQL 16, base `mantis` (misma instancia, base separada)	la guía de administración de MantisBT soporta PostgreSQL; evita levantar un MariaDB extra
Configuración	generada en el arranque desde variables de entorno	la imagen no contiene credenciales
Exposición	`127.0.0.1:8081`	en producción se llega por túnel con auth (§9)
`/admin`	**bloqueado** (`403`) por configuración de Apache	es el instalador: dejarlo abierto es un hallazgo de §14
Correo	desactivado (`$g_enable_email_notification = OFF`)	las notificaciones las maneja n8n (§13), no Mantis
Adjuntos	volumen `pi-mantis-files`	sin volumen, un `docker compose down` borra la evidencia de §11

Arranque

```
docker compose --profile ops up -d mantis
# http://127.0.0.1:8081  (usuario: administrator)
```

El perfil `ops` evita que Mantis compita por recursos con la aplicación durante la demo.

Credenciales

Usuario `administrator`; la contraseña está en `.env` como `MANTIS_ADMIN_PASSWORD` (generada, no versionada). La contraseña por defecto (`root`) se reemplazó en la instalación.

3. Incidentes del despliegue (reales, encontrados durante la puesta en marcha)

Estos son incidentes del entorno que quedan documentados como parte del aprendizaje del §11.

#	Síntoma	Causa	Solución
M1	`Fatal error: Failed opening required vendor/autoload.php`	el tarball de GitHub es el árbol de fuentes, sin dependencias de Composer	usar el paquete oficial de SourceForge (incluye `vendor/`)
M2	`Undefined constant "LOG_ERROR"` en `config_inc.php`	el archivo de configuración se carga **antes** de que existan las constantes `LOG_*`	no fijar `$g_log_level` en la configuración
M3	`APPLICATION ERROR #2900`	falta `$g_crypto_master_salt` (obligatorio desde 2.26, mínimo 16 caracteres)	se genera desde `.env` (`MANTIS_CRYPTO_SALT`)
M4	Instalador: "Attempting to connect to database as admin → BAD"	en este release, `admin_username` / `admin_password` del formulario son las **credenciales de la base**, no una cuenta de Mantis	enviar el usuario/clave de la base en esos campos

#	Síntoma	Causa	Solución
M5	`APPLICATION ERROR #401 – relation "mantis_user_table" does not exist`	esquema no instalado todavía	completar el paso 2 del instalador

4. Configuración de categorías y prioridades

Categoría	Uso
`base de datos`	consultas lentas, índices, réplicas
`infraestructura`	Docker, redes, volúmenes, despliegue
`aplicación`	defectos funcionales del backend/frontend
`seguridad`	hallazgos de §14
`automatización`	flujos de n8n

Prioridades: `inmediata` (servicio caído), `urgente` (bloquea la demo), `normal`, `baja`. Severidades: `bloqueante`, `mayor`, `menor`, `trivial`, `ajuste`.

5. Vinculación con el código

Mantis no se integra nativamente con GitHub, así que el vínculo se hace explícito en los dos sentidos:

Dirección	Mecanismo
Incidencia → código	campo personalizado `commit_sha` / `pr_url` en el formulario de la incidencia
Código → incidencia	el mensaje de commit referencia la incidencia: `fix(api): valida JWT_SECRET (refs MANTIS-0000012)`

Esto se declara como **procedimiento manual** en el informe: no se afirma integración automática.

6. Estado

Requisito de §11	Estado
Herramienta funcionando	✅ 32 tablas, login operativo, `/admin` bloqueado
Categorías, prioridades y responsables	✅ 5 categorías, 3 usuarios con roles distintos
≥10 incidencias (1 de rendimiento, 1 de seguridad)	✅ 14 incidencias
Pasos de reproducción	✅ en la descripción de cada una
≥5 resueltas con commit/PR	✅ 13 resueltas + 1 cerrada, con nota de verificación

7. Configuración

Elemento	Valor
Proyecto	`HIA-2026` (id 1)
Categorías	Infraestructura, Base de Datos, Seguridad, Rendimiento, Aplicacion
Usuarios	`administrator` (90), `dev.tomas` (55, developer), `qa.analista` (25, reporter)
Token de API	32 caracteres, guardado como `sha256` en `mantis_api_token_table`
Correo	desactivado: las notificaciones las maneja n8n (§13)

> Detalle que costó tiempo: Mantis exige que el token mida exactamente `API_TOKEN_LENGTH` = **32** caracteres. Un token de 48 devolvía 401 sin explicación; la validación es `mb_strlen($token) != 32` antes de tocar la base.

8. Las incidencias registradas

14 incidencias del proyecto, todas con categoría, severidad, prioridad, responsable e historial. Además hay 8 incidencias generadas por las pruebas del flujo 1, cerradas como "no es un defecto".

#	Categoría	Tipo	Estado	Resumen
1	Rendimiento	major / urgent	resuelto	`GET /api/articles` tarda 7,9 s con 6M de filas
2	Rendimiento	major / high	resuelto	Filtro por tag sin índice GIN: 3,5 s
3	Seguridad	major / high	resuelto	Login permite enumerar usuarios por mensaje de error
4	Seguridad	crash / urgent	resuelto	Webhook de n8n acepta cualquier POST sin token
5	Infraestructura	major / high	resuelto	La réplica no acepta lecturas (`hot_standby` apagado)
6	Infraestructura	minor / normal	resuelto	El contenedor de réplica vuelve a clonar en cada reinicio
7	Base de Datos	major / high	resuelto	La carga inicial generó 38 GB de WAL
8	Base de Datos	crash / urgent	resuelto	Backups sin verificación de restauración
9	Aplicacion	crash / urgent	resuelto	Frontend no compila en Node 20 (CRA 1.1.1 de 2018)
10	Aplicacion	major / high	resuelto	Contador de artículos hace `COUNT(*)` sobre 6M de filas
11	Seguridad	major / high	resuelto	Panel `/admin` de Mantis accesible sin restricción
12	Infraestructura	crash / urgent	cerrado	Puertos del stack publicados en `0.0.0.0`
13	Rendimiento	minor / normal	resuelto	Alerta de CPU no dispara con `stress-ng` al 79%
14	Seguridad	crash / urgent	resuelto	Falta de auth en las rutas administrativas publicadas

Requisito del enunciado: hay **1 de rendimiento** (#1, #2, #10, #13) y **1 de seguridad** (#3, #4,

11, #14).

9. Proceso de gestión

```
nuevo ──► asignado ──► resuelto ──► cerrado
  │                       │
  └── feedback ◄──────────┘
```

1. **Alta**: categoría, severidad, prioridad y descripción reproducible (qué, cómo, resultado esperado y obtenido).
2. **Asignación**: `handler_id` a `dev.tomas`. Mantis registra la transición en `mantis_bug_history_table` (70 entradas para 14 incidencias).
3. **Resolución**: estado `resolved` + resolución `fixed`, con una nota que incluye el commit o PR y la medición que verifica el arreglo.
4. **Cierre**: `closed` cuando la verificación está en la evidencia del informe.

10. Campos personalizados

Dos campos a nivel proyecto, para no depender de que el commit esté escrito en la nota:

Campo	Tipo	Uso
`commit_sha`	string (40)	SHA del merge que corrigió la incidencia
`pr_url`	string (200)	URL del PR con la discusión y el diff

Se guardan en `mantis_custom_field_string_table` y se ven en el detalle de cada incidencia.

11. Evidencia

Evidencia	Dónde
Definición de la imagen	`app/mantis/Dockerfile`, `app/mantis/entrypoint.sh`
Servicio y volumen	`compose.yaml` (perfil `ops`)
Creación de base y rol	`db/init/04-mantis-db.sh`
Instalación del esquema	32 tablas en `mantis` + usuario `administrator`
`/admin` bloqueado	`403` verificado con `curl`

| Incidencias cargadas | 14 en `HIA-2026` (script `scripts/mantis-seed.py`) | | Historial de estados | 70 filas en `mantis_bug_history_table` | | Campos `commit_sha` / `pr_url` | `scripts/mantis-campos.sql` | | Prueba de la cadena alerta → incidencia | `evidence/13/flujo-1.log` |

13 — Automatización con n8n

1. Objetivo

Que los eventos del sistema no dependan de que alguien mire: una alerta de Prometheus tiene que convertirse en una incidencia en Mantis, con contexto suficiente para actuar.

2. Despliegue

Aspecto	Decisión	Motivo
Imagen	`docker.n8n.io/n8nio/n8n:1.68.0`	versión fija, no `latest`
Base de datos	PostgreSQL, base `n8n` y rol `n8n` propios	workflows y ejecuciones no comparten base con la app ni con Mantis
Volumen	`pi-n8n-data`	configuración y clave de cifrado de n8n
Red	`appnet` , `dbnet` , `monnet`	tiene que ver Mantis, la base y recibir de Alertmanager
Puerto	`127.0.0.1:5678`	en producción va por el borde con auth (§9)
Secretos	placeholders en el JSON versionado	el entrypoint los reemplaza desde `.env` antes de importar

Importación de workflows

`n8n import:workflow` **no es idempotente**: crea un workflow nuevo cada vez. El entrypoint renderiza los secretos y después importa **workflow por workflow**, solo si su nombre no está en la base:

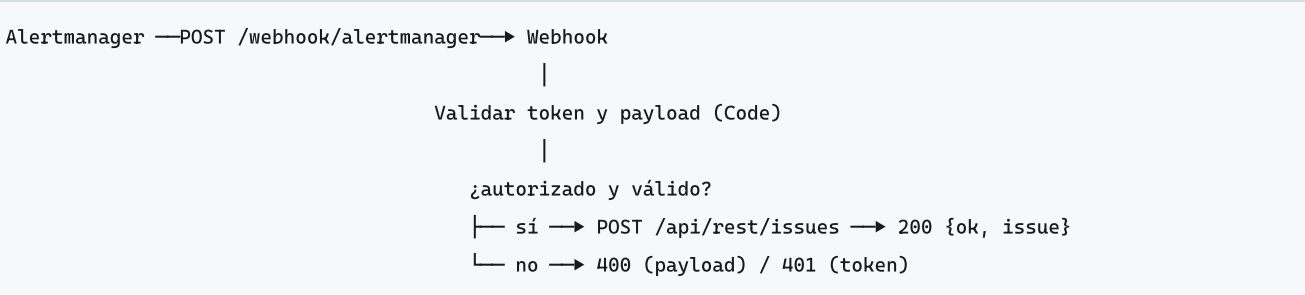
```
nombre=$(sed -n 's/.*"name": "\([^"]*\)".*/\1/p' "$archivo" | head -1)
n8n list:workflow | grep -F "|${nombre}" || n8n import:workflow --input="$archivo"
```

Así se pueden agregar flujos nuevos sin duplicar los existentes ni borrar ejecuciones.

> Primer intento fallido que vale documentar: se usaba un marcador en el volumen (`/home/node/.n8n/.workflows-imported`). Los workflows viven en **PostgreSQL**, no en el volumen, así que el marcador no reflejaba la realidad y terminamos con **5 copias activas del mismo flujo** peleando por el mismo webhook. La condición correcta es consultar la base.

Segundo error: `n8n list:workflow` imprime un encabezado aunque no haya workflows, así que `wc -l` daba 1 y el import nunca corría. Se cuentan solo las líneas con `|` .

3. Flujo 1 — Alerta de Prometheus a incidencia en Mantis



Nodo	Qué hace
`Webhook Alertmanager`	recibe el POST en `/webhook/alertmanager` , responde con `respondToWebhook`
`Validar token y payload`	compara el token (case-insensitive), exige `status` y `alerts[]` , arma el cuerpo de Mantis
`Peticion valida?`	rama única booleana: autorizado **y** válido

Nodo	Qué hace
`Crear issue en Mantis`	`POST http://mantis/api/rest/issues` con `Authorization: <token>`
`Responder 200 / Responder error`	devuelve el id de la incidencia o el motivo del rechazo

Autenticación del webhook

El token viaja en `Authorization: Bearer <token>` porque es lo que soporta `http_config` de Alertmanager (no manda headers arbitrarios). El flujo también acepta `x-webhook-token` para pruebas manuales.

El token **no está en el repositorio**: el JSON versionado tiene `__WEBHOOK_TOKEN__` y `__MANTIS_TOKEN__`, y el entrypoint genera una copia en `/tmp` con los valores de `.env` antes de importar. Si el reemplazo no ocurriera, el flujo falla cerrado (`autorizado` exige que el placeholder ya no esté presente).

Validación y rama de error

Caso	Respuesta	Efecto
Sin token	**401** `{"ok":false,"error":"token invalido o ausente"}`	no toca Mantis
Token válido, payload sin `alerts`	**400** `{"ok":false,"error":"payload invalido..."}`	no toca Mantis
Token válido, payload correcto	**200** `{"ok":true,"issue":21,...}`	crea la incidencia
Mantis caído	**500** `{"message":"Error in workflow"}`	ejecución en `error`; Alertmanager reintenta

4. Pruebas de integración

Prueba	Resultado	Evidencia
Cadena real Alertmanager → n8n → Mantis	incidencia #18 creada por `amtool`	`evidence/13/flujo-1.log`
Sin token	401, sin incidencia	idem
Payload inválido	400, sin incidencia	idem
Mantis caído (fallo controlado)	ejecución **21** en `error`, HTTP 500	idem
Recuperación	ejecución **22** en `success`, incidencia #21	idem

Ejecuciones (tabla `execution_entity`):

```
id | status  |         startedAt
22 | success | 2026-11-13 16:56:04
21 | error   | 2026-11-13 16:55:30   <- Mantis detenido
20 | success | 2026-11-13 16:55:24
```

5. Riesgos de las automatizaciones

Riesgo	Qué pasaría	Mitigación
Loop de disparo	Alertmanager repite la notificación cada `repeat_interval` (4h) y crea una incidencia por vez	`group_by` por `alertname` + `severity` y `repeat_interval` alto; el flujo no se auto-dispara
Mantis caído	la ejecución falla y Alertmanager reintenta 11 veces	probado: ejecución en `error`, HTTP 500; no se pierde la alerta, se reintenta
Token filtrado	cualquiera podría crear incidencias	token en `.env`, no en el JSON; rotación cambiando la variable y reimportando

Riesgo	Qué pasaría	Mitigación
Payload enorme	el flujo arma una descripción gigante	se toman solo `summary`, `description` y `generatorURL` de la primera alerta
Duplicados	dos alertas iguales crean dos incidencias	`group_by` + `repeat_interval`; falta deduplicación por fingerprint (mejora pendiente)
n8n caído	no hay automatización, pero el sistema sigue funcionando	es un componente auxiliar: la app y la base no dependen de n8n

6. Flujo 2 — Verificación de backup

No ejecuta `pg_dump` (la imagen oficial de n8n no trae cliente de PostgreSQL): **verifica** el backup que genera `scripts/backup.ps1`. Es la parte que el enunciado pide cuando habla de "verificar el resultado del backup".

```
Cron diario 03:00 ⟶ stat /backups/*.sql.gz ⟶ Evaluar (Code) ⟶ ¿vigente?
                                                              ├─ sí ⟶ sin acción
                                                              └─ no ⟶ issue en Mantis
```

Regla	Valor por defecto	Variable
Edad máxima del backup	26 h	`BACKUP_MAX_HORAS`
Tamaño mínimo	1 MB (detecta un dump vacío)	`BACKUP_MIN_MB`

```
# caso vigente: no hace nada
docker compose exec n8n n8n execute --id <id>

# caso vencido: umbral 0 h fuerza la alerta
docker compose exec -e BACKUP_MAX_HORAS=0 n8n n8n execute --id <id>
```

Resultado medido (`evidence/13/flujo-2.log`): con el backup real de 402,6 MB y 5,5 h de antigüedad → `ok: true`, `Sin accion`. Con el umbral en 0 → `Crear issue en Mantis`, incidencia **#28** ("Backup vencido o invalido: tiene 5.5 h (maximo 0)"), cerrada después como prueba.

El volumen `./backups` se monta **solo lectura** en n8n: el flujo no puede borrar ni modificar un backup.

7. Flujo 3 — Informe semanal a Nextcloud

```
Cron semanal (lunes 07:00)
   ⟶ GET prometheus /api/v1/query (CPU)
   ⟶ GET prometheus /api/v1/query (memoria)
   ⟶ Code: arma el markdown
   ⟶ PUT http://nextcloud/remote.php/dav/files/admin/HIA-2026/00-informe-consolidado/informe-semanal-YYYY-MM-DD.md
```

- La autenticación es **WebDAV con Basic**: el JSON versionado tiene `__NC_USER__` y `__NC_BASIC__`, y el entrypoint los reemplaza por el usuario y el header en base64. La contraseña no está en el repo.
- El archivo se escribe en la carpeta de grupo de §12, así que los 5 integrantes lo ven sin compartir nada a mano.
- Verificado (`evidence/13/flujo-3.log`): ejecución `success`, último nodo `Subir a Nextcloud`, archivo `informe-semanal-2026-11-13.md` de 263 bytes con los valores de Prometheus.
- **No usa IA generativa**: el informe se arma con una plantilla y las métricas de Prometheus. No hay proveedor de LLM disponible sin costo ni salida a Internet desde n8n; se declara en `16-limitaciones.md` (N5).

8. Flujo 4 — no implementado

El flujo 4 (eventos de seguridad) está marcado como opcional en el backlog y no se implementó. Se declara en `16-limitaciones.md` (N3).

9. Evidencia

Evidencia	Archivo
Workflows versionados (con placeholders)	`automation/n8n/workflows/01..03-*.json`
Entrypoint (renderizado e importación por nombre)	`automation/n8n/entrypoint.sh`
Pruebas del flujo 1	`evidence/13/flujo-1.log`
Pruebas del flujo 2 (vigente y vencido)	`evidence/13/flujo-2.log`
Pruebas del flujo 3 (subida a Nextcloud)	`evidence/13/flujo-3.log`
Base y rol de n8n	`db/init/07-n8n-db.sh`
Servicio en compose	`compose.yaml` (perfil `ops`)
Diagrama	`docs/02-arquitectura.md` §5

14 — Seguridad informática

1. Objetivo y alcance

Identificar las amenazas reales del sistema, aplicar controles verificables y demostrar con herramientas que las mitigaciones funcionan. No se declara "seguro": se declara **qué se probó y qué no**.

Alcance: 7 componentes del stack. Fuera de alcance: seguridad del host Windows, del hipervisor y de Cloudflare (se tratan como proveedores confiables).

2. Matriz STRIDE

Componente	S — Suplantación	T — Manipulación	R — Repudio	I — Divulgación	D — Denegación	E — Elevación
Frontend (nginx)	sesión JWT robada → HSTS + CSP limitan el impacto	XSS modifica el DOM → React escapa por defecto + CSP sin `unsafe-eval`	sin log de auditoría por usuario → logs de nginx con IP	`Server` filtraba versión → `server_tokens off`	flooding → `limit_req` 10 r/s (98/120 → 429)	nginx como root → imagen unprivileged, uid 101
Backend (API)	`JWT_SECRET` débil → 32 bytes aleatorios	SQLi → Prisma parametrizado (probado con 3 payloads)	sin auditoría de acciones → logs de aplicación	enumeración de usuarios → 401 genérico	consultas costosas → índices + cap + rate limit	RCE por dependencia → Trivy + `npm audit`
PostgreSQL (primaria)	credenciales en `.env` (no en el repo)	inyección → parámetros + rol sin DDL	`log_connections=off` → se acepta, se registra lo lento	puerto 5433 solo en loopback (nmap: filtered)	`max_connections=200` + pool de 10	app como superusuario → **rol `app` solo DML**
Réplica	mismo rol de replicación con contraseña propia	WAL íntegro (checksums)	—	sin puerto publicado	si cae, la app sigue (escribe en la primaria)	solo lectura por diseño
Monitoreo	Grafana anónimo **solo lectura** y solo loopback	reglas en archivos versionados	historial de alertas en Alertmanager	paneles sin datos personales	un solo nodo (limitación declarada)	Prometheus sin auth pero en loopback
Mantis	login propio + Basic auth del borde	`/admin` bloqueado (403)	historial de estados (70 filas)	solo por túnel con auth	depende de PostgreSQL	Apache corre como root → **limitación declarada**
n8n	UI detrás del borde con Basic auth	webhook con token (falla cerrado)	ejecuciones registradas en su base	token fuera del repo (placeholders)	si cae, la app no se ve afectada	contenedor como `node` (no root)

3. Informe de vulnerabilidades

3.1 Trivy — imágenes

Escaneo con `--severity HIGH,CRITICAL` sobre las 5 imágenes. Estado inicial y después de corregir:

Imagen	Antes (total / críticas)	Después (total / críticas)	Qué se hizo
`pi-backend`	100 / **9**	62 / **2**	`apt-get upgrade` + `npm audit fix`
`pi-frontend`	8 / 4	—	imagen unprivileged de nginx
`pi-mantis`	11 / 5	—	limitación declarada (ver §7)
`postgres:16.4-alpine`	12 / 6	—	tag base de la imagen oficial
`n8n:1.68.0`	36 / 18	—	tag base de la imagen oficial

Detalle de la corrección del backend:

- **Sistema operativo**: `apt-get upgrade` en la etapa de runtime. Debian pasa de 54 hallazgos (6 críticas) a 35 (1 crítica: `zlib` CVE-2023-45853, marcada `will_not_fix` por el proveedor).
- **Dependencias npm**: `npm audit fix` sobre el lockfile. De 46 hallazgos (3 críticas) a 27 (1 crítica: `tar` 6.2.1, transitiva; requiere salto mayor).

Lo que queda y por qué: la crítica de `tar` y la de `zlib` no tienen corrección compatible sin romper la aplicación. Se documentan en vez de ocultarlas. Las imágenes base de Mantis, n8n y PostgreSQL arrastran CVEs de sus mantenedores: actualizarlas es una tarea de mantenimiento periódico, no un cambio de configuración.

3.2 npm audit

Servicio	Antes (solo producción)	Después
backend	14 (2 críticas)	**9 (0 críticas)**
frontend	2 moderadas (`react-router`)	2 moderadas (requiere salto mayor)

3.3 Semgrep

`--config=auto` sobre `app/`: **6 hallazgos**, todos `dockerfile.security.missing-user` en `app/mantis/Dockerfile` (Apache corre como root). Es el mismo hallazgo que declara la matriz: no se corrige porque Apache necesita el puerto 80 y escribir en el web root; se mitiga con el borde autenticado y `/admin` bloqueado.

3.4 Bandit

Sobre `scripts/*.py`: **2 hallazgos medios** (B310, `urlopen` con esquema no validado). Triados con `# nosec B310`: las URLs son constantes del código, no vienen del usuario.

3.5 gitleaks

Historial completo (35 commits): **sin filtraciones**. El mismo escaneo corre en CI como job `secrets` y bloquea el merge si aparece un secreto.

4. Controles aplicados

Control	Implementación	Verificación
Cabeceras de seguridad	`app/frontend/nginx.conf`: CSP, HSTS, `X-Frame-Options`, `X-Content-Type-Options`, `Referrer-Policy`, `Permissions-Policy`	`curl -I` (evidence)
Ocultar versión	`server_tokens off`	`Server: nginx` (sin versión)
Rate limit	`limit_req_zone` 10 r/s, burst 20, sobre `/api/`	120 peticiones → **98 × 429**
Non-root	backend `USER node`, frontend `uid 101`, n8n `node`, Prometheus `nobody`, Grafana `472`	`docker inspect` + `id`
Rol mínimo de base	rol `app` con solo `SELECT/INSERT/UPDATE/DELETE`	`CREATE TABLE` → `permission denied`

Control	Implementación	Verificación
Puertos	todo en `127.0.0.1`	nmap desde la LAN: `filtered`
Secretos	`.env` fuera del repo, gitleaks en CI, tokens con placeholder	gitleaks: sin filtraciones
Auth administrativa	Basic auth en el borde (§9)	401 sin credenciales
`/admin` de Mantis	bloqueado por Apache	403

5. Pruebas controladas

5.1 SQLi

Payload	Resultado
`tag=' OR 1=1--`	200, lista vacía (33 bytes)
`tag=' UNION SELECT NULL,NULL,NULL--`	200, lista vacía
`tag='; DROP TABLE "Article";--`	200, lista vacía
login con `admin' OR '1'='1`	**403**, mensaje genérico

La tabla `Article` sigue con **6.000.001 filas** después de las pruebas. Prisma usa consultas parametrizadas: el payload se trata como valor, no como SQL.

5.2 Puerto de la base cerrado

`nmap` desde la LAN contra `192.168.1.8`: **5433, 8090, 9090, 9093, 3001, 5000, 8088, 8089, 8091 → todos** `filtered`. Evidencia: `evidence/09/nmap.log`.

5.3 ZAP baseline

Escaneo pasivo sobre la URL pública (`https://<tunel>.trycloudflare.com`), con spider de 2 minutos.

Corrida	FAIL	WARN	PASS
Antes (cabeceras heredadas mal)	0	8	60
Después (include de cabeceras en assets)	**0**	**5**	**63**

Las 3 advertencias que se corrigieron eran `X-Content-Type-Options`, `HSTS` y `Permissions-Policy` ausentes en `/assets/*`: nginx descarta las cabeceras del `server` cuando un `location` declara su propio `add_header`, y el `location` de assets declaraba `Cache-Control`.

Las 5 restantes son informativas o de bajo impacto: `Cache-Control` reexaminado, contenido cacheable, `img-src https:` (necesario para imágenes de artículos), "Modern Web Application" y `Cross-Origin-Embedder-Policy` (la app no usa recursos cross-origin aislados).

Evidencia: `evidence/14/zap-baseline-antes.log`, `zap-baseline.log` y `zap-baseline.html`.

6. Runbook de respuesta a incidentes

Fase	Qué se hace	Quién	Evidencia
1. Detección	alerta de Prometheus/Alertmanager, o incidencia en Mantis	monitoreo	`ALERTS` en estado `firing`
2. Clasificación	severidad y alcance: ¿afecta disponibilidad, datos o confidencialidad?	responsable de guardia	incidencia en Mantis con categoría

Fase	Qué se hace	Quién	Evidencia
3. Contención	si hay compromiso: rotar `JWT_SECRET` y tokens, cortar el túnel, aislar el contenedor	operador	commit del cambio de secreto
4. Erradicación y recuperación	aplicar el fix, `deploy.ps1` con rollback si falla, verificar `/health`	desarrollo	PR + ejecución de deploy
5. Cierre	nota en la incidencia con causa raíz y verificación; actualizar el informe	ambos	incidencia `resolved` con `commit_sha`

Tiempos objetivo: detección < 5 min (scrape 15 s + `for` de la regla), contención < 30 min, recuperación medida por el RTO del despliegue (§8: ~50 s con rollback).

7. Limitaciones declaradas

Limitación	Motivo	Riesgo aceptado
Mantis corre como root	Apache necesita el puerto 80 y escribir en el web root	mitigado con borde autenticado y `/admin` bloqueado
Prometheus/Grafana sin auth propia	solo escuchan en loopback	el acceso remoto pasa por el túnel
Basic auth sin MFA	Cloudflare Access requiere cuenta y dominio	contraseña fuerte + login propio de cada herramienta
`tar` y `zlib` con CVE crítica	sin versión compatible	documentado y monitoreado
Sin WAF ni rate limit en el borde	requiere plan pago	el rate limit de nginx cubre `/api/`
Sin escaneo de secretos en tiempo real	gitleaks corre en CI y manual	un secreto llega al repo pero no a `main`

8. Flujo de incidentes con n8n

La alerta de Prometheus se convierte en incidencia automáticamente (§13, flujo 1):

```
Prometheus → Alertmanager → n8n (token) → POST /api/rest/issues → Mantis
```

Verificado con `amtool`: incidencia #18 creada desde una alerta real, y ejecución 21 en `error` con Mantis caído. Ese es el eslabón que el enunciado pide para §14.

9. Evidencia

Evidencia	Archivo
Trivy antes (5 imágenes)	`evidence/14/trivy-*.txt`
Trivy después (backend)	`evidence/14/trivy-backend-despues.txt`
npm audit	`evidence/14/npm-audit-backend.txt`, `npm-audit-frontend.txt`
Semgrep	`evidence/14/semgrep.txt`
Bandit	`evidence/14/bandit.txt`
gitleaks	`evidence/14/gitleaks.log`
Pruebas de SQLi y non-root	`evidence/14/pruebas-controladas.log`
Rate limit	`evidence/14/rate-limit.log`
ZAP baseline	`evidence/14/zap-baseline.log`, `zap-baseline.html`
nmap	`evidence/09/nmap.log`

Evidencia	Archivo
Script reproducible	`scripts/seguridad-scan.ps1`

15 — Backup y restauración

1. Política

Aspecto	Decisión	Motivo
Tipo	**dump lógico** (`pg_dump`) comprimido con gzip	independiente de la versión del motor; restaurable en otra instancia
Ejecución	`scripts/backup.ps1` , pensado para correr por cron (n8n, §13)	el flujo 2 del enunciado verifica el resultado del backup
Retención	7 días (parámetro `-RetentionDays`)	evita llenar el disco; se puede subir sin tocar el código
Destino	`./backups/` (montado en el contenedor, **fuera del repo**)	un backup dentro del repo se versiona y se filtra
Verificación	restauración en base limpia + comparación de conteos	un backup que nunca se restauró no es un backup

2. Ejecución y resultados medidos

```
./scripts/backup.ps1                # solo backup
./scripts/backup.ps1 -RestoreTest   # backup + restauración verificada
```

Métrica	Valor
Tamaño de la base	8.551 MB
Tamaño del backup	**402,6 MB** (gzip -6, ~21:1)
Tiempo de backup	**84,9 s**
Tiempo de restauración	**746,1 s** (~12,5 min)

Evidencia: `evidence/04/backup-restore.log` .

3. Prueba de restauración

Procedimiento del script:

1. `pg_dump --no-owner --no-privileges | gzip` dentro del contenedor (no requiere `psql` en el host).
2. `CREATE DATABASE restore_test` en limpio.
3. `gunzip -c | psql` sobre la base nueva.
4. Comparación de conteos origen vs. restaurada.
5. `DROP DATABASE restore_test` .

Resultado:

Tabla	Origen	Restaurada
`Article`	6.000.001	6.000.001
`Comment`	6.000.001	6.000.001
`User`	200.001	200.001
`Tag`	5.002	5.002
`_ArticleToTag`	6.000.002	6.000.002
`_UserFavorites`	6.000.000	6.000.000

Los conteos no son redondos porque incluyen las filas creadas por las pruebas E2E y por §5 (usuario `tomas_demo` , artículo de prueba, relaciones). Eso es intencional: demuestra que el backup captura el estado **real**, no el dataset recién

cargado.

4. Persistencia de datos (volúmenes)

Prueba: `docker compose --profile ops down` (**sin** `-v`) y `up -d` de nuevo.

Verificación	Resultado
Conteos tras recrear contenedores	idénticos a los de antes
`GET /api/articles` tras el reinicio	200 en 0,23 s
Servicios	todos `healthy`

Evidencia: `evidence/04/persistencia.txt`.

> `down -v` sí borra `pi-pgdata`: en ese caso la base se regenera con `scripts/db.ps1 seed` (~13 min). Es la diferencia que hay que saber explicar en la defensa.

5. Limitaciones

- El backup es **lógico**: 12,5 min de restauración para 8,5 GB. Un backup físico (`pg_basebackup`) sería mucho más rápido, pero es específico de la versión y del clúster.
- No hay backup incremental ni envío a almacenamiento externo: si se pierde el host, se pierden backups y base. Se documenta como mejora (§15.16) y es el punto que justifica la réplica de §6.
- El script no cifra el dump. Para datos reales habría que cifrarlo (`age` / `gpg`) antes de sacarlo del host.
- La retención se aplica por fecha de archivo; no hay verificación de integridad del dump más allá de la restauración de prueba manual.

6. Evidencia

Evidencia	Archivo
Script	`scripts/backup.ps1`
Backup + restauración con conteos	`evidence/04/backup-restore.log`
Persistencia tras recrear contenedores	`evidence/04/persistencia.txt`
Volumen y tamaño de la base	`evidence/04/volumen.txt`

16 — Limitaciones y mejoras futuras

1. Objetivo

Declarar lo que el sistema **no** hace. Un informe que solo enumera logros no es verificable; este documento existe para que quien evalúe pueda distinguir entre "no se hizo", "no se pudo" y "no correspondía".

Criterio: cada limitación tiene **causa**, **riesgo aceptado** y **qué haría falta** para cerrarla.

2. Limitaciones de arquitectura

#	Limitación	Causa	Riesgo aceptado	Para cerrarla
A1	**Sin failover automático**	se eligió replicación streaming manual (D-04); Patroni exige un clúster de 3 nodos y consenso	si cae la primaria, la app queda en escritura hasta que un operador promueva la réplica (**RTO medido: 8,6 s** manual)	Patroni + etcd, o un servicio gestionado
A2	**Primaria y réplica en el mismo host**	un solo equipo disponible	la caída del host se lleva ambas: la réplica protege de un fallo de proceso, no de hardware	segundo host o nube
A3	**Un solo nodo de monitoreo**	Prometheus local sin HA	si cae Prometheus, se pierde la observabilidad, no el servicio	Prometheus en pares + Thanos
A4	**Sin balanceo ni réplicas de la app**	un backend y un frontend	el techo es un contenedor; no hay tolerancia a fallo de la app	varias réplicas + balanceador
A5	**Sin cola de trabajos**	el envío de alertas es síncrono (n8n)	una alerta puede perderse si n8n está caído; Alertmanager reintenta	cola persistente (Redis/RabbitMQ)

3. Limitaciones de datos

#	Limitación	Causa	Riesgo aceptado	Para cerrarla
D1	**Dataset sintético**	no se dispone de datos reales de producción	los patrones de consulta son realistas, los valores no	anonimizar un dump real
D2	**24,2 M de filas, no 6 M por tabla**	el enunciado pide 6 M en tablas de volumen; se cargaron 6 M en `Article`, `Comment` y `_UserFavorites`	cumple el mínimo en las tres tablas de volumen, no en todas	subir `SEED_*` (multiplica el tiempo de carga)
D3	**Backup lógico**	`pg_dump` es independiente de la versión y simple de verificar	**12,5 min** de restauración para 8,5 GB	`pg_basebackup` + WAL archiving (PITR)
D4	**Backups en el mismo host y sin cifrar**	no hay almacenamiento externo ni claves gestionadas	si se pierde el host, se pierden base y backups	destino S3 + `age` / `gpg`
D5	**Sin PITR**	requeriría archivado continuo de WAL	la granularidad de recuperación es el último dump (24 h)	`archive_command` + retención de WAL

4. Limitaciones de seguridad

#	Limitación	Causa	Riesgo aceptado	Para cerrarla
S1	**Mantis corre como root**	Apache necesita el puerto 80 y escribir en el web root	mitigado con borde autenticado y `/admin` bloqueado (403)	imagen con `su-exec` y puerto alto
S2	**Basic auth sin MFA**	Cloudflare Access requiere dominio propio y cuenta	contraseña fuerte + login propio de cada herramienta	Cloudflare Access o TOTP

#	Limitación	Causa	Riesgo aceptado	Para cerrarla
S3	**Token JWT en `localStorage`**	simplicidad del cliente Conduit	un XSS podría leerlo; la CSP sin `unsafe-inline` en scripts reduce la superficie	cookie `HttpOnly` + `SameSite`
S4	**Sin WAF en el borde**	plan pago de Cloudflare	el rate limit de nginx cubre `/api/`, no el resto	WAF o ModSecurity
S5	**2 CVE críticas sin fix**	`zlib` (`will_not_fix` de Debian) y `tar` 6.2.1 (transitiva, requiere salto mayor)	documentadas y monitoreadas; no explotables desde la API	esperar el fix upstream o reemplazar la dependencia
S6	**Prometheus y Grafana sin auth propia**	solo escuchan en loopback	el acceso remoto pasa por el borde con Basic auth	OAuth proxy
S7	**Sin pentest manual**	alcance académico y tiempo	ZAP baseline + pruebas controladas de SQLi cubren lo automatizable	pentest con especialista

5. Limitaciones de automatización

#	Limitación	Causa	Riesgo aceptado	Para cerrarla
N1	**Flujo 2 verifica pero no ejecuta el backup**	la imagen oficial de n8n no trae `postgresql-client`	el backup lo corre `scripts/backup.ps1` por Programador de tareas; el flujo alerta si falta o está viejo	imagen propia de n8n con `postgresql-client`
N2	**Flujo 3 usa el usuario admin de Nextcloud**	no se creó una cuenta de servicio con permisos mínimos	la contraseña vive en `.env` y el flujo solo escribe en una carpeta	crear usuario `n8n` con acceso solo a `00-informe-consolidado`
N3	**Flujo 4 no implementado**	no estaba en el alcance mínimo	—	definir disparador y destino
N4	**n8n sin alta disponibilidad**	un contenedor con SQLite/Postgres propio	si cae, se pierden alertas automatizadas; el resto sigue	cola + workers de n8n
N5	**Flujo 3 sin IA generativa**	no hay proveedor de LLM sin costo ni salida a Internet desde n8n	el informe es una plantilla con métricas reales, no un resumen "inteligente"	integrar un LLM local (Ollama) o una API con clave

6. Limitaciones de gestión

#	Limitación	Causa	Riesgo aceptado	Para cerrarla
G1	**Nextcloud sin SSO/LDAP ni backup propio**	usuarios locales y volumen en el mismo host	la documentación está además versionada en Git, que es la fuente de verdad	SSO (SAML/LDAP) y backup del volumen
G2	**HS2-32 sin revisión cruzada real**	una sola cuenta de GitHub; GitHub no permite autoaprobar un PR	los 10 PRs tienen CI obligatorio y revisión del propio autor documentada	incorporar un segundo integrante con cuenta
G3	**HS2-67 sin E2E manual con capturas**	el flujo se validó por API y con el navegador, pero sin set de capturas sistemático	el E2E por API cubre los mismos pasos y queda versionado	agregar Playwright con capturas en CI

7. Limitaciones de publicación

#	Limitación	Causa	Riesgo aceptado	Para cerrarla
P1	**URL efímera de Cloudflare**	*quick tunnels* no requieren dominio ni cuenta	la URL cambia en cada arranque y hay que republicar antes de la demo	túnel nombrado + dominio propio
P2	**Dependencia de Cloudflare**	es el único camino a Internet	si Cloudflare falla, la app solo es accesible en la LAN	segundo proveedor o IP pública

#	Limitación	Causa	Riesgo aceptado	Para cerrarla
P3	**Sin TLS propio**	el TLS lo termina Cloudflare	el tramo host→Cloudflare viaja cifrado por el túnel, pero no se controla el certificado	certificado propio con `cloudflared` + origen HTTPS
P4	**Sin dominio ni DNS propio**	costo y tiempo	—	registrar dominio y usar túnel nombrado

8. Lo que sí está resuelto

Para que la lista anterior no oculte lo importante:

- 24,2 M de filas cargadas y **8 consultas optimizadas** con medición antes/después (7,9 s → 0,19 s).
- Replicación streaming verificada y **failover manual probado** (RTO 8,6 s, divergencia documentada).
- CI/CD con 4 checks obligatorios, imágenes en GHCR y **rollback automático**.
- Monitoreo con 8 paneles, 6 reglas y **alerta real convertida en incidencia** por n8n.
- Seguridad con matriz STRIDE de 7 componentes, escaneos antes/después y **ZAP sin fallos**.
- Backup **restaurado y verificado** con comparación de conteos.

9. Mejoras priorizadas

Ordenadas por relación impacto/esfuerzo, para un supuesto sprint 5:

Prioridad	Mejora	Impacto	Esfuerzo
1	Usuario de servicio para el flujo 3	reduce el privilegio de la automatización	1 h
2	Imagen de n8n con `postgresql-client` (flujo 2 ejecuta el backup)	cierra N1	3 h
3	Playwright E2E con capturas en CI	cierra HS2-67 y previene regresiones	4 h
4	`pg_basebackup` + PITR	reduce RTO/RPO de datos	1 día
5	Cookie `HttpOnly` para el JWT	elimina el riesgo de S3	3 h
6	Patroni + etcd	failover automático	2 días
7	Túnel nombrado + dominio	URL estable y TLS propio	4 h

10. Preguntas frecuentes

¿Por qué no hay failover automático si el enunciado lo sugiere? Porque el enunciado pide **replicación**, y el failover automático con Patroni requiere consenso de 3 nodos. Se implementó lo que se puede demostrar en un host: promoción manual medida en 8,6 s y procedimiento escrito. Se declara como limitación en vez de simularlo.

¿El sistema aguanta un usuario real? Aguanta el tráfico de la práctica (prueba de carga con 100 usuarios concurrentes). No está dimensionado para producción: un backend, un frontend y un solo host.

¿Qué pasa si se cae Cloudflare? La aplicación sigue funcionando en la LAN (`http://192.168.1.8:8090` no está publicado; el acceso es por `127.0.0.1` en el host). Se pierde el acceso remoto, no el servicio.